ECG multietiqueta con PTB-XL

Grupo 9 - TAIA - Universidad de La Sabana. Borrador para revisión; autores pendientes.

¿Qué aporta una red sobre la señal frente a una línea base de características manuales?

Comparamos calidad, calibración y costo. Uso exclusivamente académico; sin aplicación clínica.

Datos: 21.388 ECG con diagnóstico

PTB-XL 1.0.3, CC BY 4.0. ECG de 10 s, 12 derivaciones y 100 Hz.

Cinco etiquetas compatibles: NORM, MI, STTC, CD, HYP. Un 24,1 % tiene más de una.

Train: 17.084 ECG; val: 2.146; test: 2.158. Pacientes separados con strat_fold 1-8 / 9 / 10.

El test no decide el experimento

Imputación, escalado y normalización: solo train. Hiperparámetros y mejor época: solo val.

Ocho configuraciones por familia, semilla de búsqueda 123. Selección por AUC macro de val. Semillas finales 42, 43 y 44.

Umbral por clase elegido en val. No se usa argmax porque las etiquetas no se excluyen.

Dos formas de representar el ECG

Clásicos: 210 características de amplitud, espectro y RR, más edad y sexo. RF y XGBoost.

CNN 1D residual: señal completa, 363.781 parámetros. CNN+LSTM: extractor residual y recurrencia bidireccional, 464.901 parámetros.

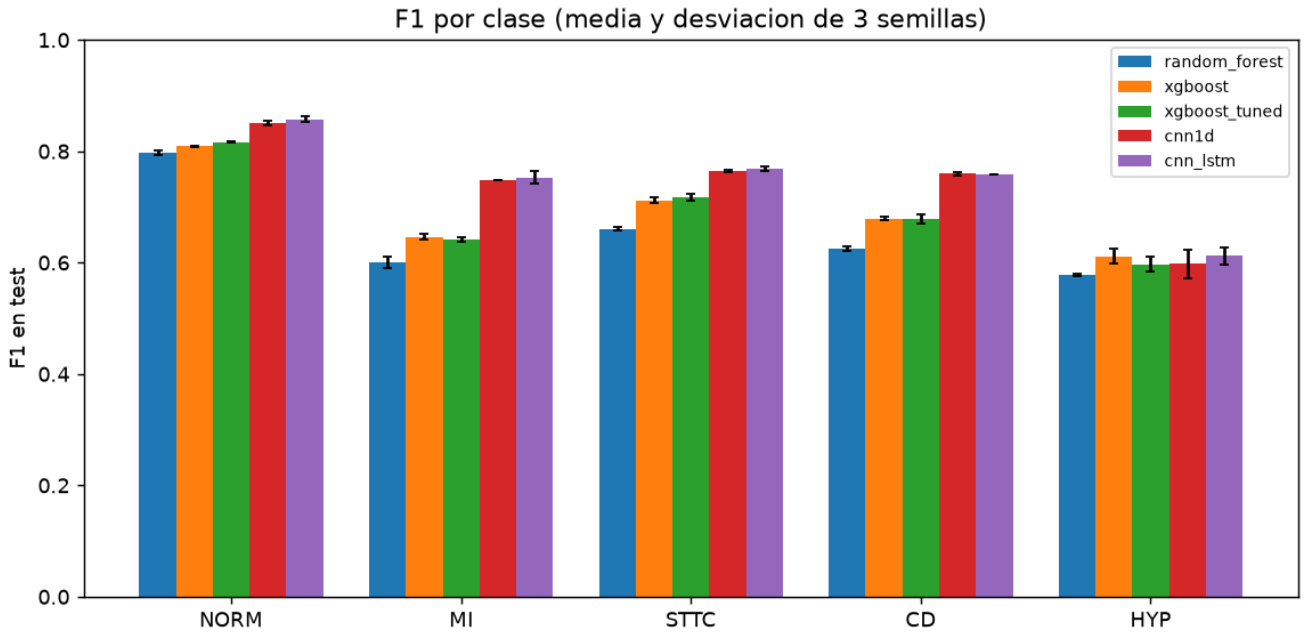
AdamW, BCE, parada temprana y mejor época restaurada. Máximo 60 épocas o 5 min. Igual número de trials, no igual cómputo total.

Las redes mejoran las métricas globales

Modelo	F1 macro	AUC macro	Brier	ECE	Final (s)	Búsqueda (s)
RF	0,652 ± 0,002	0,866 ± 0,001	0,119 ± 0,000	0,073 ± 0,000	19 ± 2	-
XGB	0,692 ± 0,002	0,891 ± 0,001	0,104 ± 0,001	0,049 ± 0,001	55 ± 2	-
XGB ajustado	0,690 ± 0,004	0,894 ± 0,001	0,107 ± 0,000	0,068 ± 0,002	92 ± 1	319
CNN 1D	0,744 ± 0,005	0,927 ± 0,001	0,085 ± 0,002	0,040 ± 0,010	137 ± 8	1454
CNN+LSTM	0,750 ± 0,003	0,928 ± 0,001	0,084 ± 0,002	0,039 ± 0,008	170 ± 27	1302

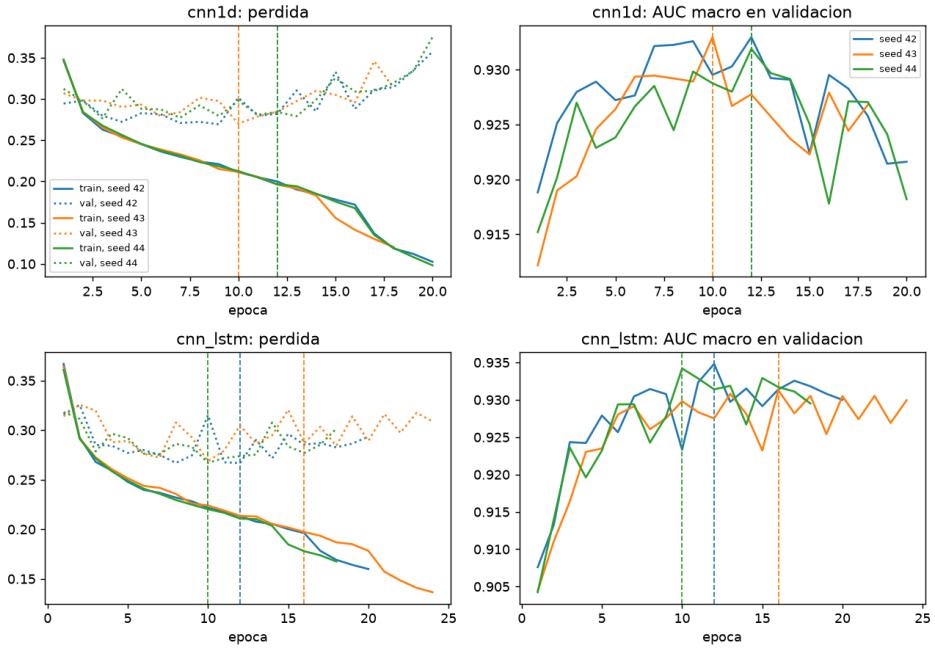
Test fijo; media ± desviación entre tres semillas. La desviación NO es un intervalo de confianza sobre pacientes nuevos.

HYP sigue siendo el punto débil



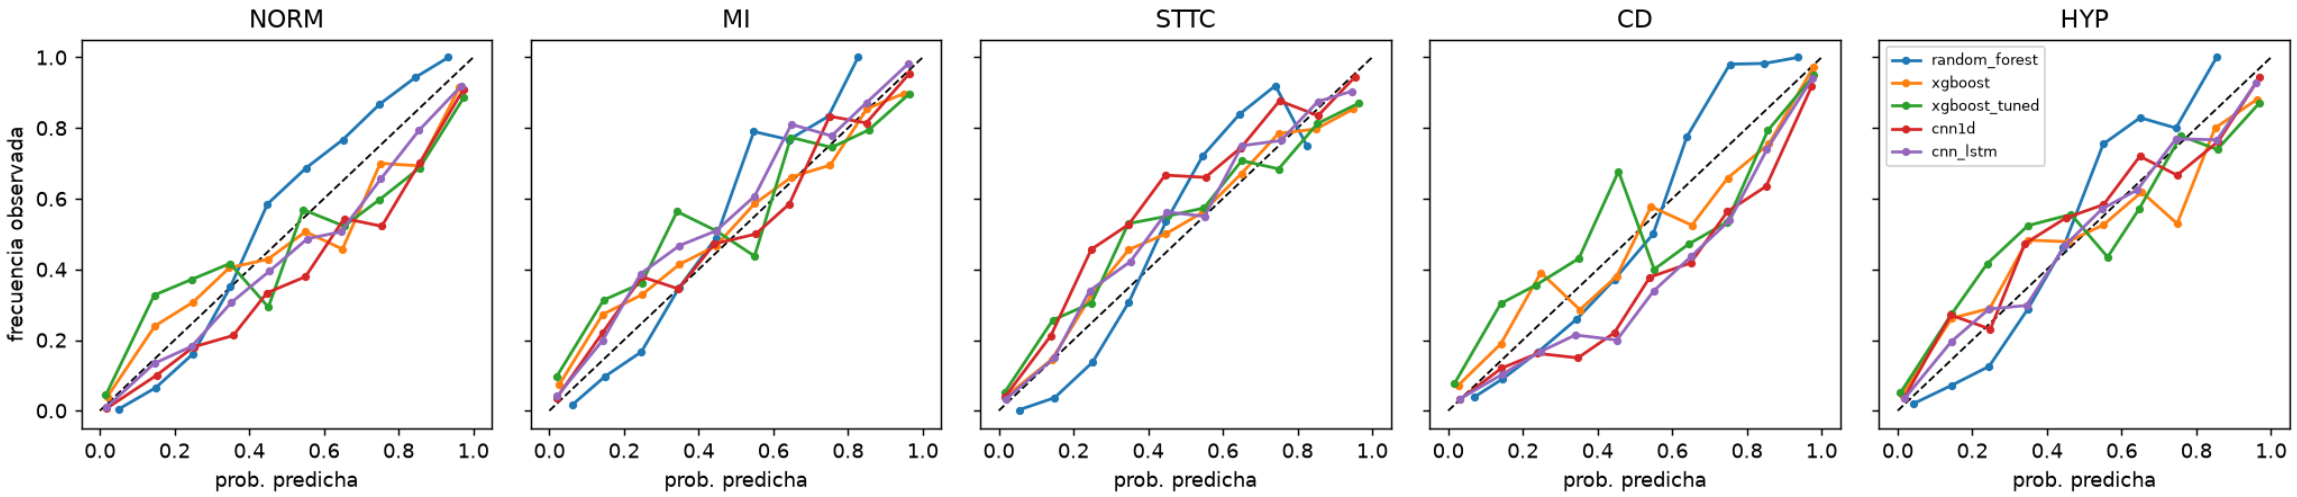
La mejora se concentra en MI y CD. CNN+LSTM no gana en todas las clases. No hay prueba estadística entre redes.

Se conserva la mejor época de validación



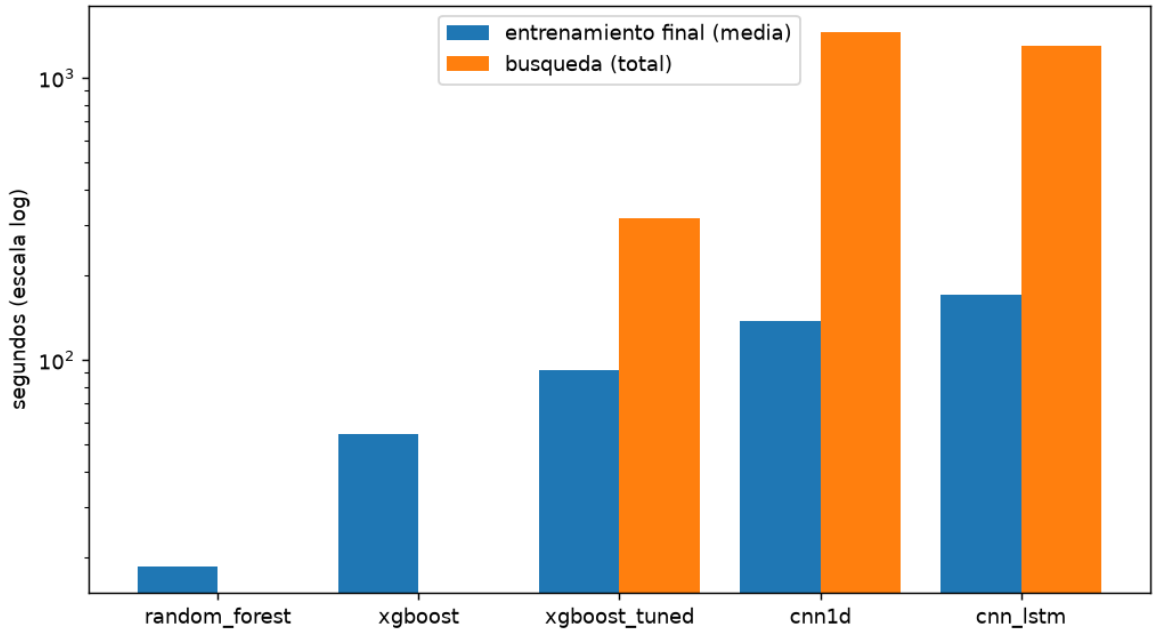
Curvas separadas de las semillas 42, 43 y 44. Dos trials de CNN 1D fueron lentos y llegaron solo a cuatro épocas; la causa en cuDNN es una hipótesis.

Calibración medida, no recalibración



ECE media: XGBoost 0,049; CNN 1D 0,040; CNN+LSTM 0,039. Diagramas: semilla 42. Temperature scaling todavía no realizado.

La calidad tiene un costo distinto



Clásicos en CPU y redes en GPU. CNN+LSTM tarda más en entrenar que CNN 1D; no hay ventaja estadísticamente demostrada. Sin validación externa ni auditoría por subgrupos.

Conclusión y trabajo pendiente

Las redes superan descriptivamente a estas líneas base en esta partición; HYP permanece cerca de F1 0,60. No se afirma equivalencia entre redes ni utilidad clínica.

Sigue: revisión del grupo, autores, roles, declaración de IA y ensayo. Ampliaciones: subgrupos, bootstrap por paciente y recalibración en val, sin seleccionar con test.

Fuentes: Wagner et al. (2020), doi:10.1038/s41597-020-0495-6; Strodthoff et al. (2021), doi:10.1109/JBHI.2020.3022989. Resultados y hashes: docs/evidence/manifest.json.