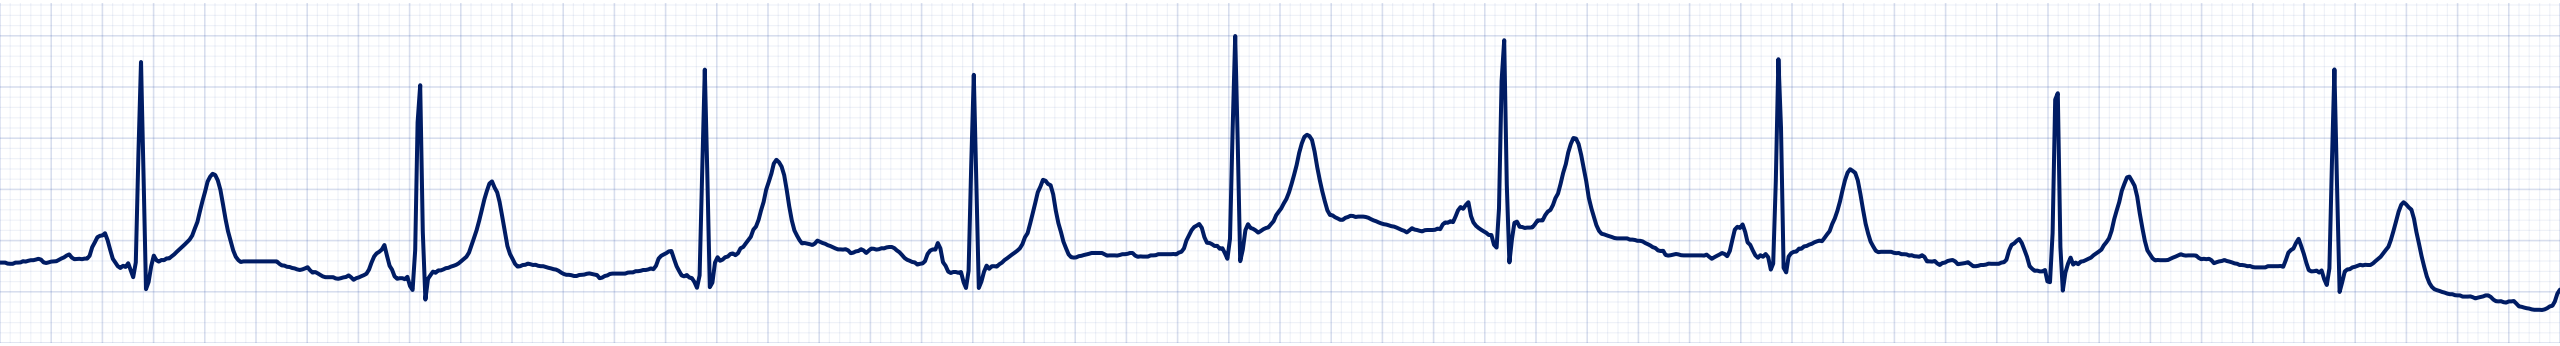
¿Una red que lee la señal cruda supera a 210 características hechas a mano?

Clasificación multietiqueta de ECG con PTB-XL

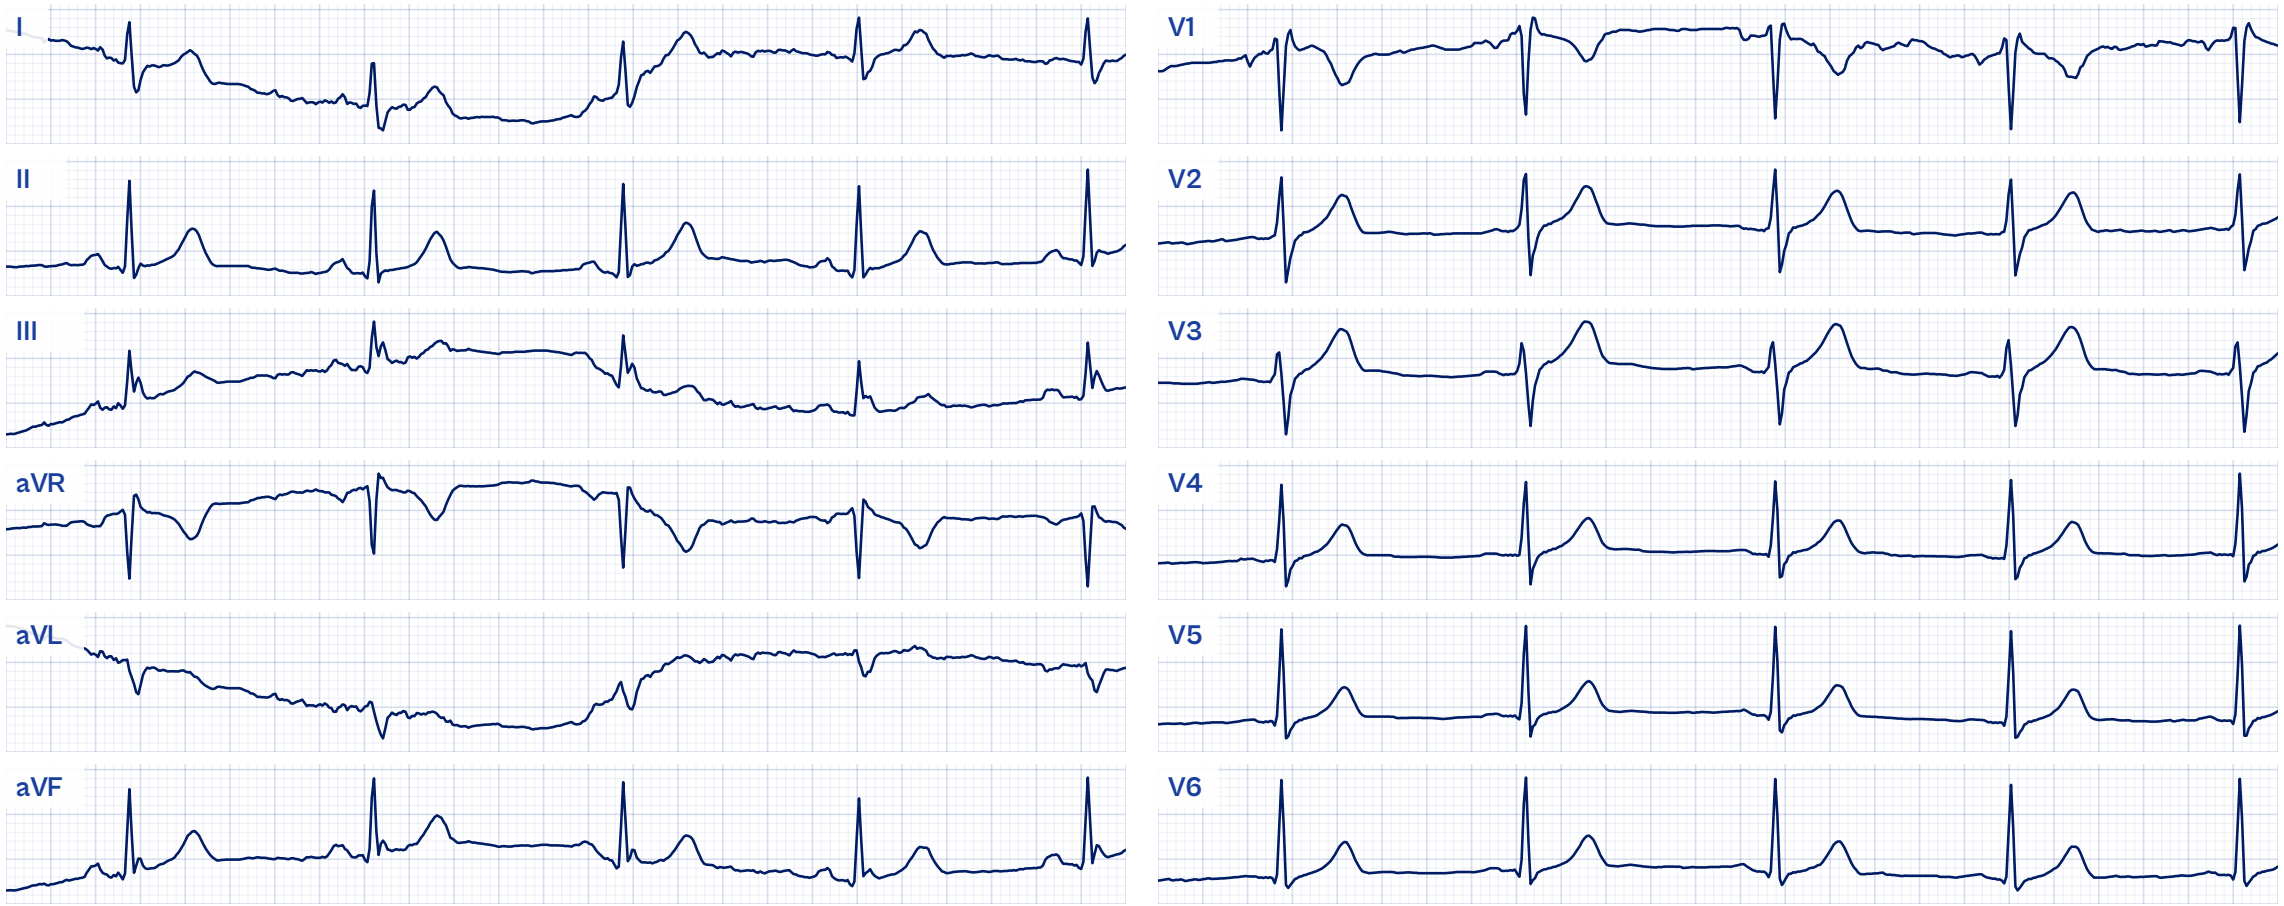


Edgar Julian Mendez Ortegon · Noel Eduardo Perez Barrios · William Alejandro Moncada Cifuentes

Grupo 9 · TAIA · Maestría en Inteligencia Artificial · Universidad de La Sabana · Octubre de 2026

ECG real de PTB-XL: registro 4805, derivación II, 10 segundos. Uso académico, sin aplicación clínica.

Un ECG son 12 vistas del corazón, registradas durante 10 segundos



Registro 4805 de PTB-XL, diagnóstico normal. Se muestran 5 de los 10 s. A 100 Hz son 1.000 muestras por derivación: 12 × 1.000 números es todo lo que recibe la red.

Cinco diagnósticos que pueden aparecer en el mismo paciente

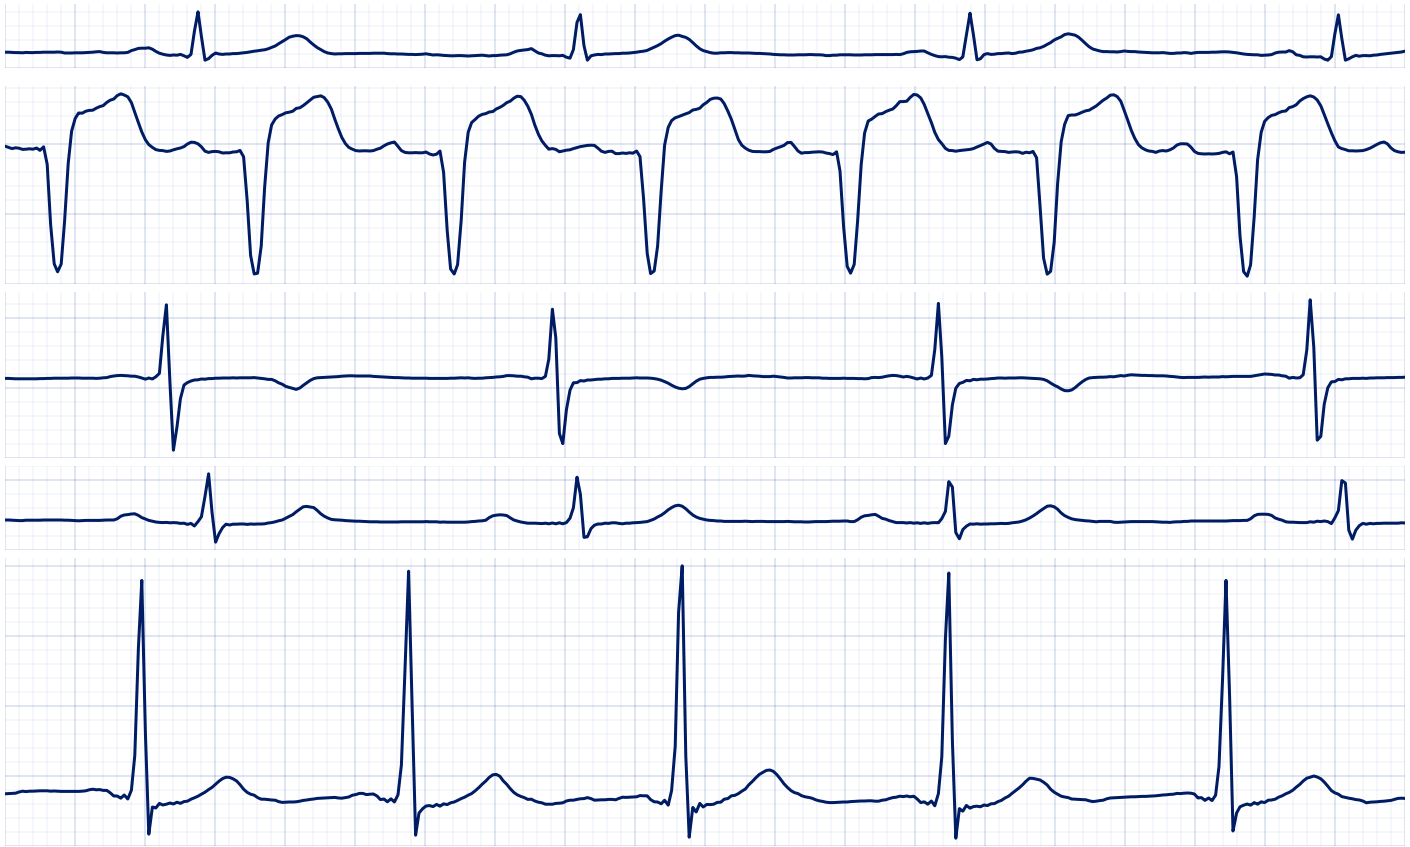
Normal
Ritmo sinusal normal

Infarto de miocardio
Infarto anterior: ondas Q y ST elevado unos 6 mm

Alteraciones del ST y la onda T
Isquemia: ondas T negativas y simétricas

Trastorno de conducción
Bloqueo AV de primer grado: PR de unos 250 ms

Hipertrofia
Hipertrofia ventricular izquierda: R de unos 42 mm en V5



NORM · DII
ECG 4805

MI · V2
ECG 12796

STTC · V4
ECG 12903

CD · DII
ECG 4387

HYP · V5
ECG 9112

Las cinco filas usan la misma escala vertical, como el papel del electrocardiógrafo.

21.388 ECG con diagnóstico de cardiólogo

24,1 % tiene más de una etiqueta

Por eso es **multietiqueta**: cinco salidas independientes, no una sola clase

El conjunto de prueba no tomó ninguna decisión

Entrenamiento

17.084 ECG · folds 1 a 8

Ajusta los pesos, la imputación y el escalado

Validación

2.146 ECG · fold 9

Elige hiperparámetros, mejor época y umbral por clase

Prueba

2.158 ECG · fold 10

Solo se mira al final, una vez

- Ningún paciente aparece en dos particiones: usamos **strat_fold** de PTB-XL.
- Semillas fijas: 123 para la búsqueda; 42, 43 y 44 para los modelos finales.
- Mismo presupuesto por familia: 8 configuraciones al azar, elegidas por ROC-AUC macro en validación.

Dos maneras de leer el mismo latido

Línea base: lo que medimos nosotros

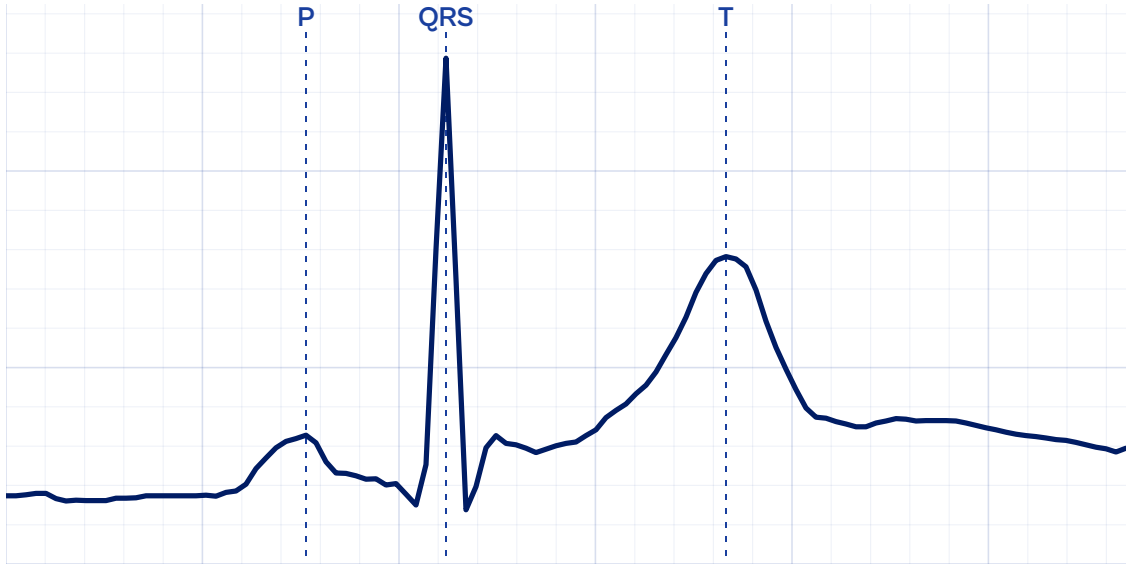
210 características por registro: amplitudes, espectro, ritmo RR, edad y sexo.

Random Forest y XGBoost.

Redes: lo que aprende el modelo

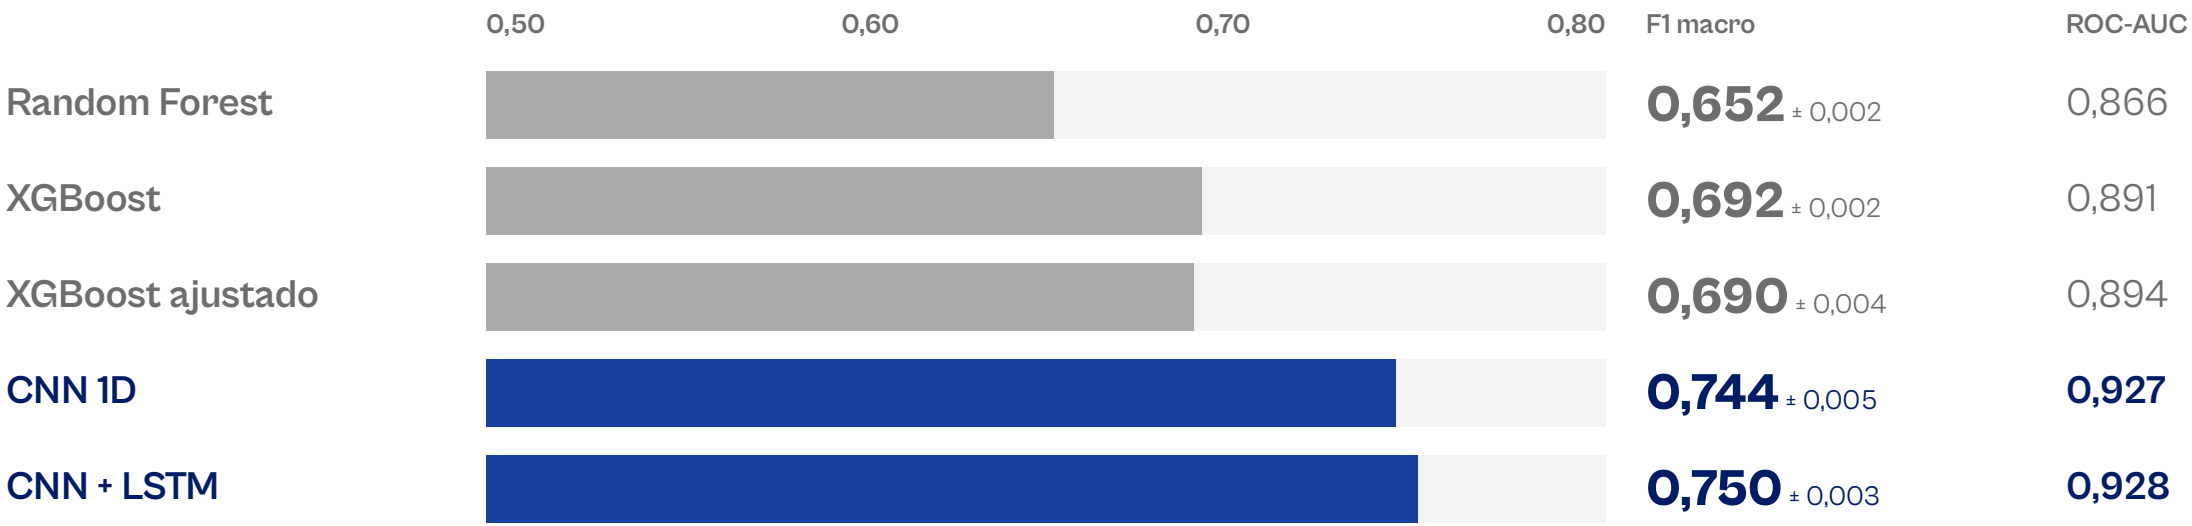
La **señal completa**, sin reglas previas.

CNN 1D residual (363.781 parámetros) y CNN + LSTM bidireccional (464.901).



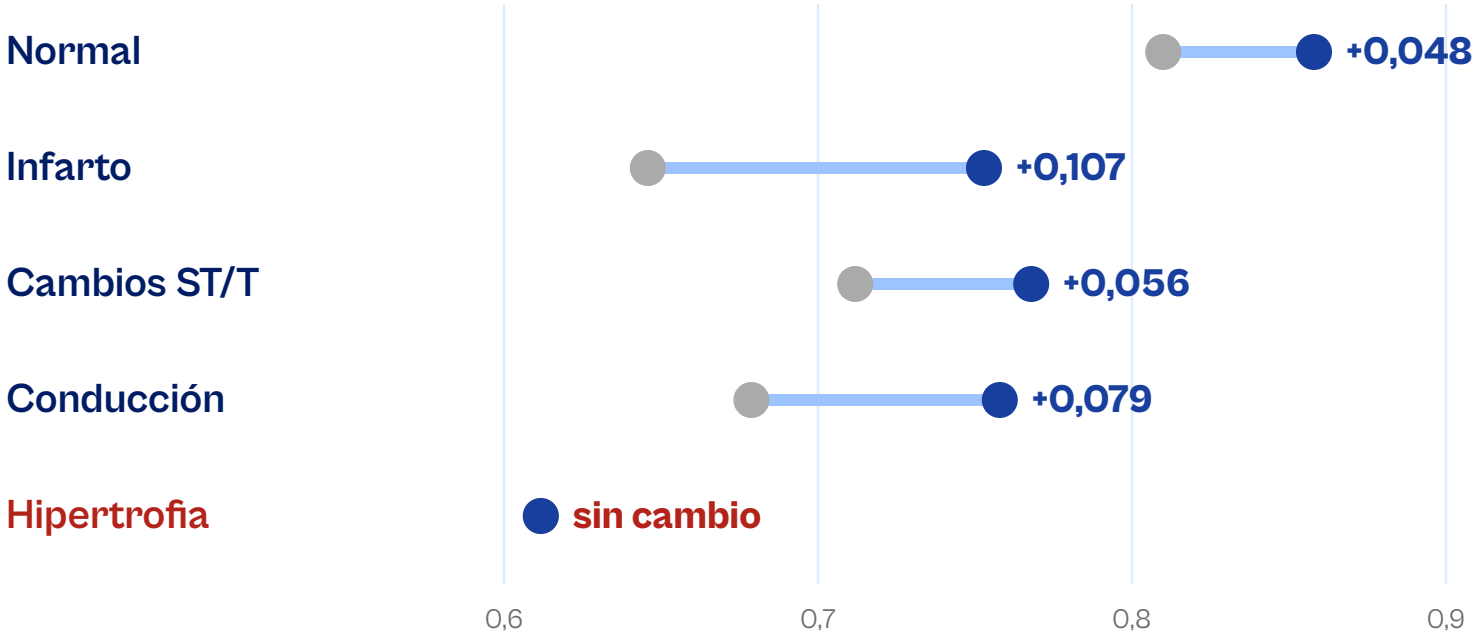
Latido real del registro 4805: onda P, complejo QRS y onda T.

Leer la señal cruda sube el F1 macro de 0,69 a 0,75



Prueba: 2.158 ECG. Media ± desviación entre tres semillas. Esa desviación mide la variación del entrenamiento, no es un intervalo de confianza. CNN 1D y CNN + LSTM quedan dentro de esa variación: no afirmamos que una supere a la otra.

La ganancia está en infarto y conducción; la hipertrofia no mejora



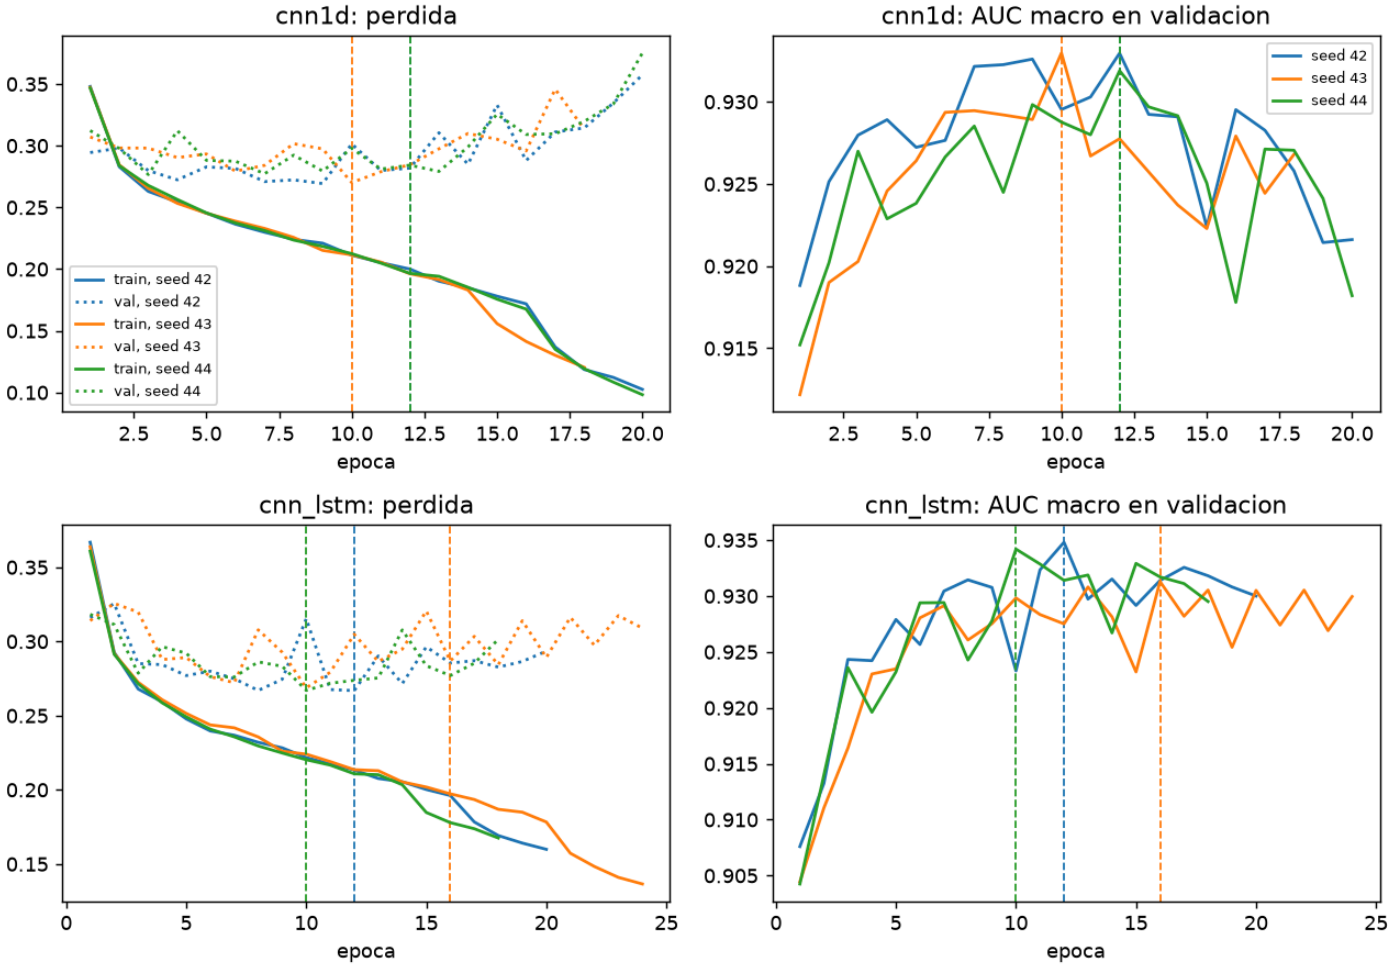
XGBoost

CNN + LSTM

F1 por clase en prueba, media de tres semillas.

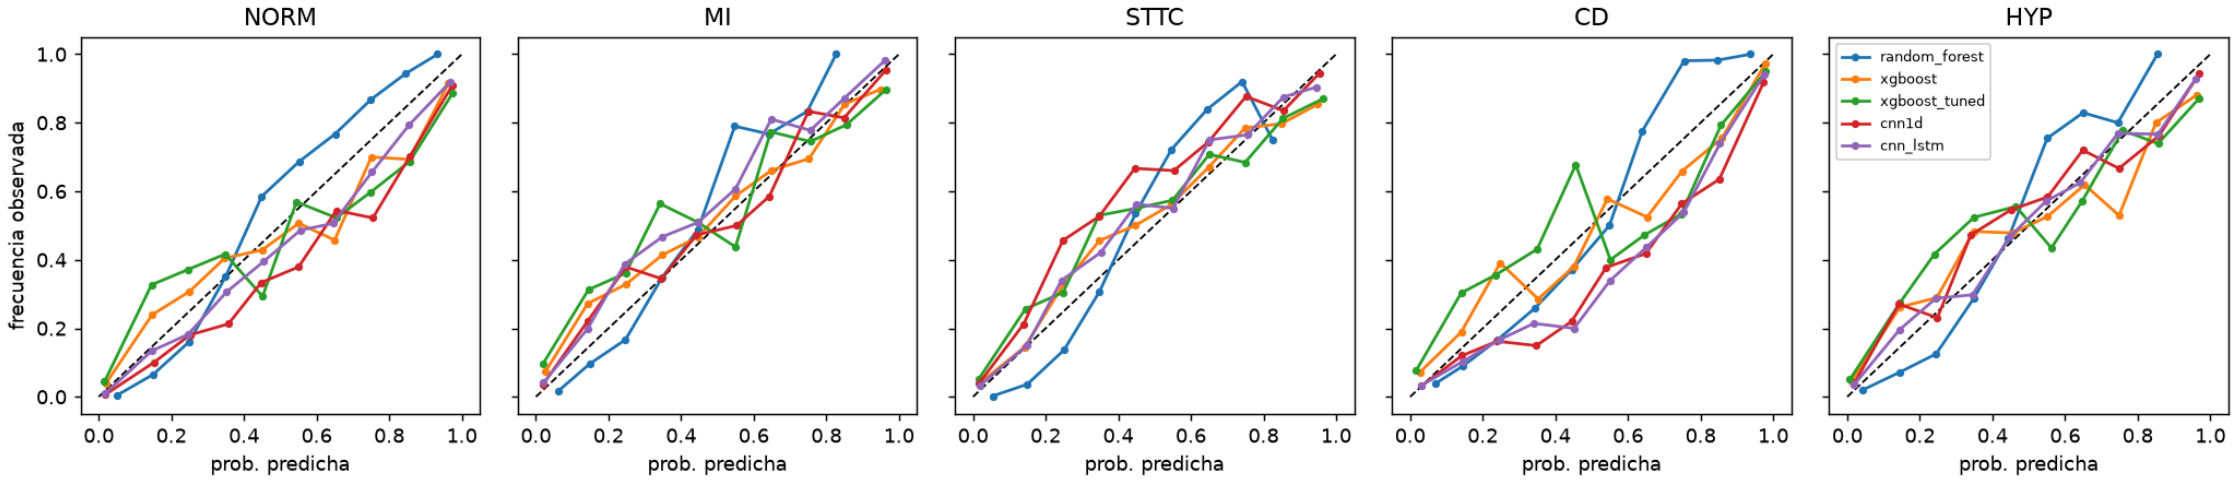
HYP es la clase menos frecuente y se queda cerca de 0,61 con todos los modelos. No probamos si el límite es el desbalance, el ruido de etiqueta o la señal.

Cada red se queda con su mejor época de validación



Máximo 60 épocas o 5 minutos por corrida, paciencia de 8 épocas y se restauran los pesos de la mejor época según AUC en validación. Dos configuraciones de CNN 1D corrieron lento y se cortaron en la época 4; lo reportamos como limitación.

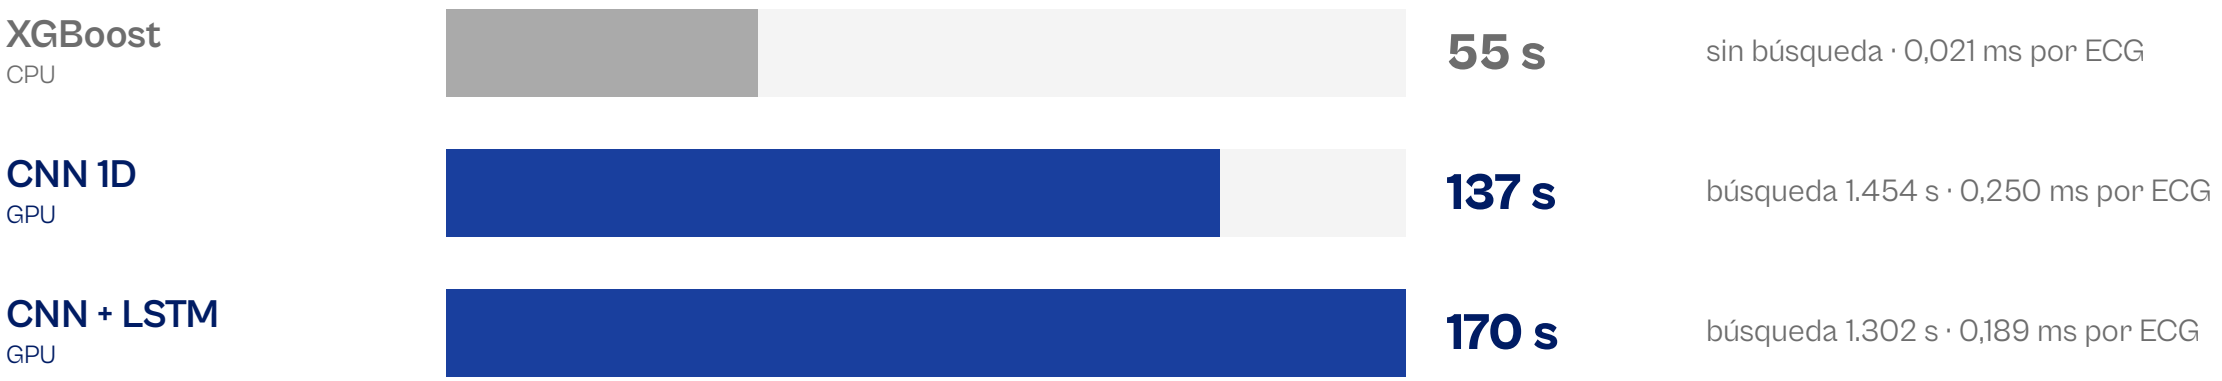
Las redes calibran mejor, pero no las recalibramos



ECE **0,049** XGBoost ECE **0,040** CNN 1D ECE **0,039** CNN + LSTM

Diagramas de la semilla 42. No aplicamos escalado de temperatura; si se hace, debe ajustarse solo en validación. Calibrar bien aquí no garantiza probabilidades confiables en otro hospital.

La mejora cuesta hasta 3 veces más tiempo de entrenamiento



Entrenamiento final medio por semilla. XGBoost corre en CPU (Ryzen 5 3600) y las redes en GPU (GTX 1660 SUPER), así que igualamos el número de configuraciones, no el cómputo total. Lo reportamos tal cual.

Lo que podemos afirmar, y lo que no

Afirmamos

- En esta partición, las redes superan a la línea base en F1, AUC y calibración.
- La mejora se concentra en infarto y trastornos de conducción.
- Ninguna decisión se tomó mirando el conjunto de prueba.

No afirmamos

- Que la CNN + LSTM sea mejor que la CNN 1D.
- Que el modelo sirva en otro hospital o con pacientes reales.
- Que funcione igual por sexo, edad o equipo: no lo medimos.

Siguiente paso: bootstrap pareado por paciente, escalado de temperatura ajustado en validación y análisis por subgrupos.

Wagner et al. (2020), Scientific Data, doi:10.1038/s41597-020-0495-6 · Strodthoff et al. (2021), IEEE JBHI, doi:10.1109/JBHI.2020.3022989 · Código: github.com/AlejoMoncada/taia-proyecto-final