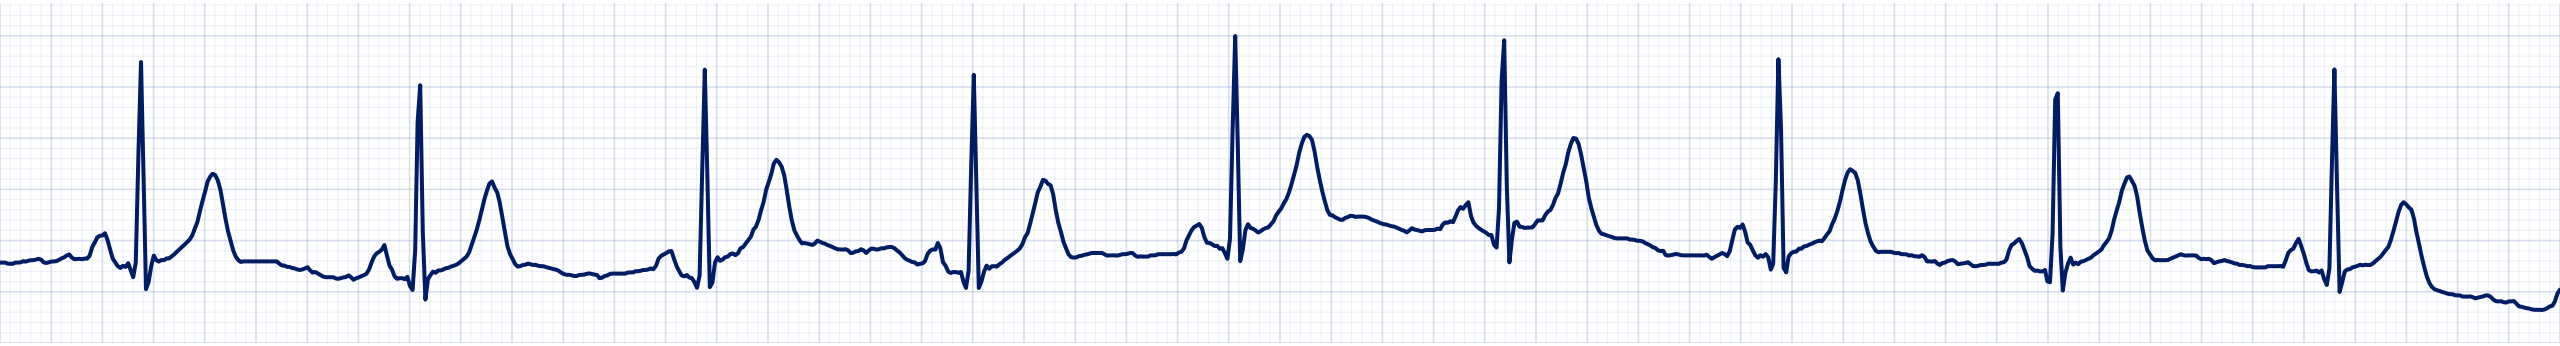
¿Una red que lee la señal cruda supera a 210 características hechas a mano?

Clasificación multietiqueta de ECG con PTB-XL

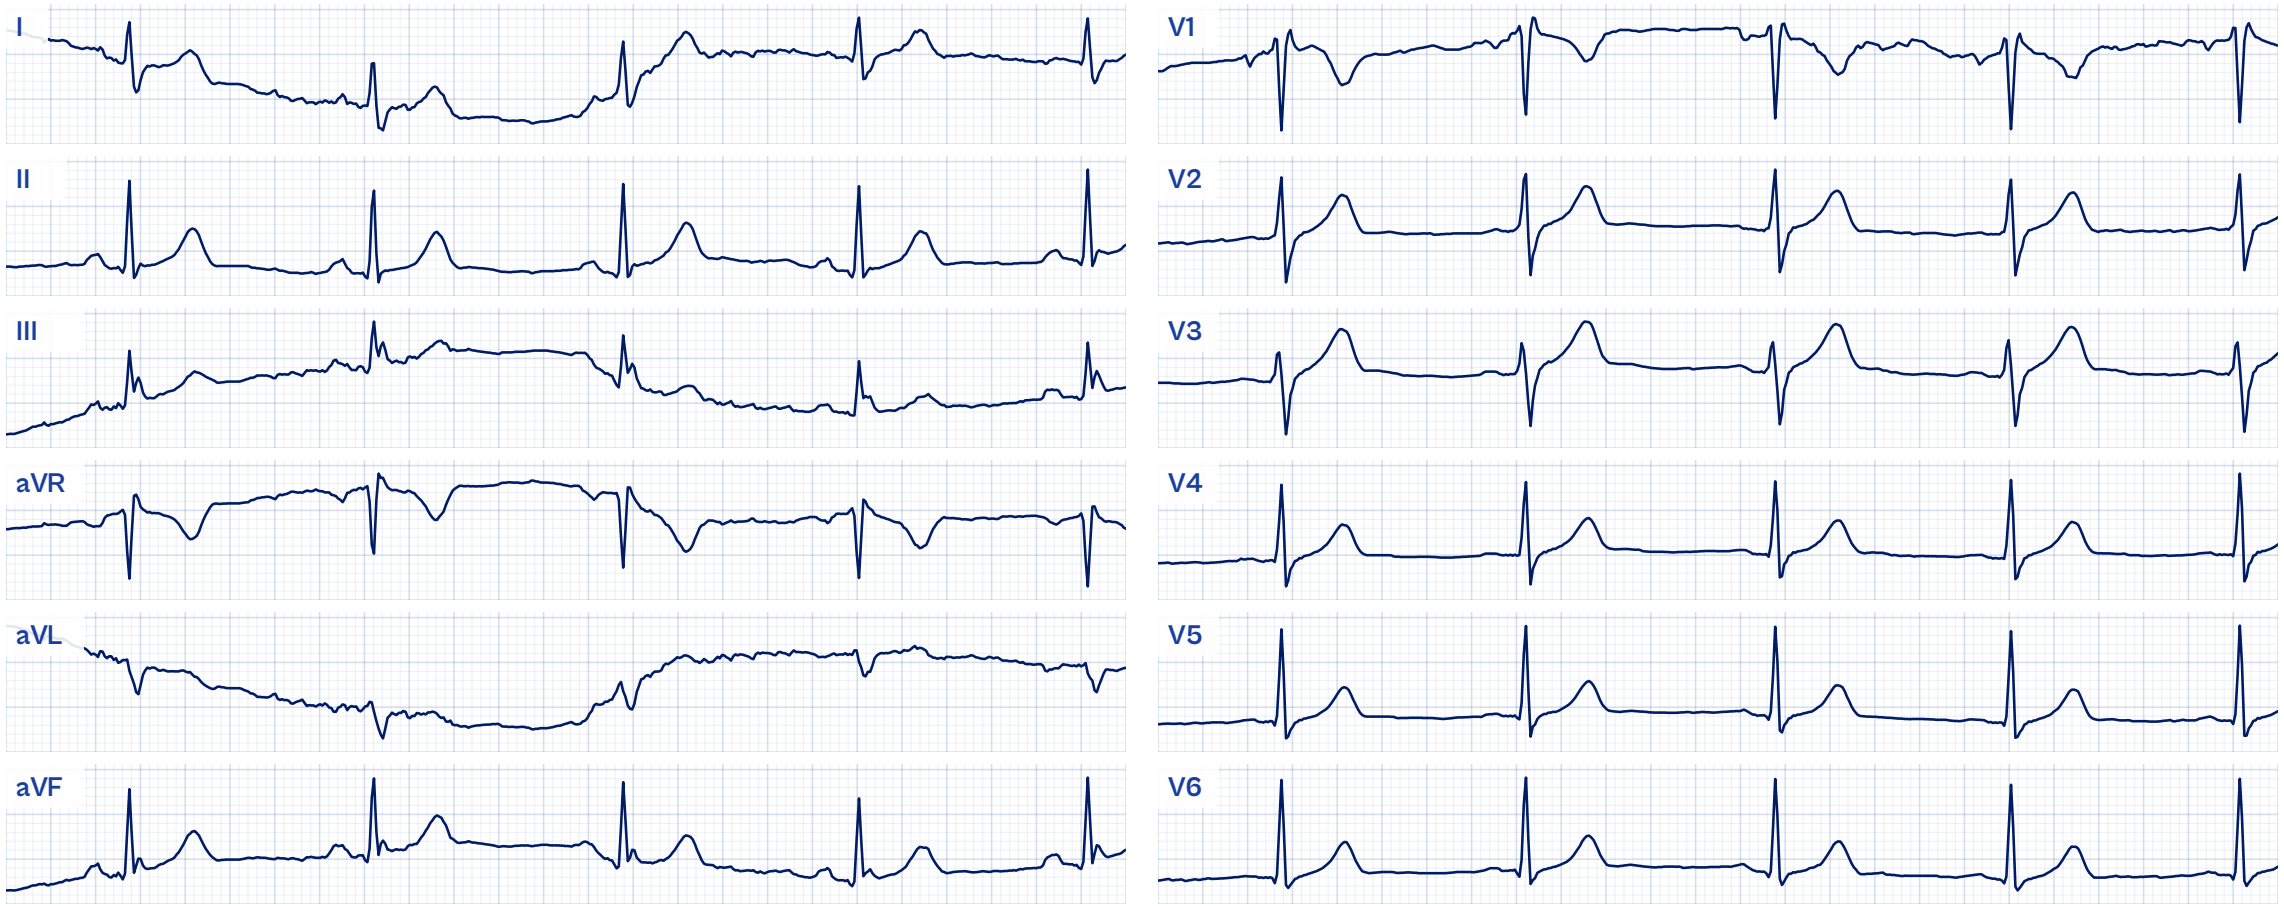


Edgar Julian Mendez Ortegon · Noel Eduardo Perez Barrios · William Alejandro Moncada Cifuentes

Grupo 9 · TAIA · Maestría en Inteligencia Artificial · Universidad de La Sabana · Octubre de 2026

ECG real de PTB-XL: registro 4805, derivación II, 10 segundos. Uso académico, sin aplicación clínica.

Un ECG son 12 vistas del corazón, registradas durante 10 segundos



Registro 4805 de PTB-XL, diagnóstico normal. Se muestran 5 de los 10 s. A 100 Hz son 1.000 muestras por derivación: 12 × 1.000 números es todo lo que recibe la red.

Cinco diagnósticos que pueden aparecer en el mismo paciente

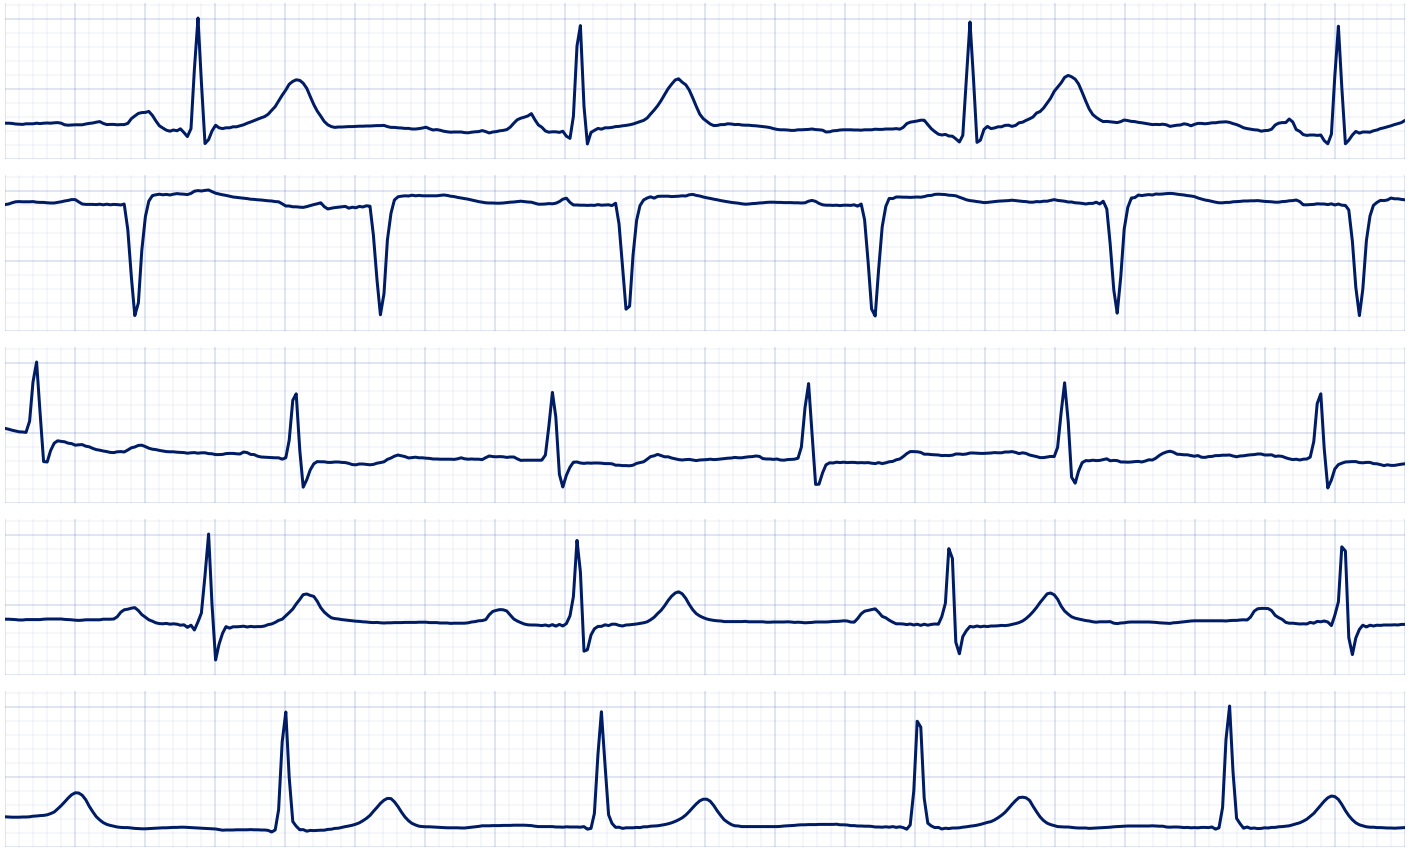
Normal
Ritmo sinusal normal

Infarto de miocardio
Infarto anteroseptal con elevación del ST

Alteraciones del ST y la onda T
Isquemia: descenso del ST e inversión de la onda T

Trastorno de conducción
Bloqueo AV de primer grado: PR prolongado

Hipertrofia
Hipertrofia ventricular izquierda: criterio de voltaje



NORM · DII
ECG 4805

MI · V2
ECG 16052

STTC · V5
ECG 941

CD · DII
ECG 4387

HYP · V5
ECG 1996

21.388 ECG con diagnóstico de cardiólogo

24,1 % tiene más de una etiqueta

Por eso es **multietiqueta**: cinco salidas independientes, no una sola clase

El conjunto de prueba no tomó ninguna decisión

Entrenamiento

17.084 ECG · folds 1 a 8

Ajusta los pesos, la imputación y el escalado

Validación

2.146 ECG · fold 9

Elige hiperparámetros, mejor época y umbral por clase

Prueba

2.158 ECG · fold 10

Solo se mira al final, una vez

- Ningún paciente aparece en dos particiones: usamos **strat_fold** de PTB-XL.
- Semillas fijas: 123 para la búsqueda; 42, 43 y 44 para los modelos finales.
- Mismo presupuesto por familia: 8 configuraciones al azar, elegidas por ROC-AUC macro en validación.

Dos maneras de leer el mismo latido

Línea base: lo que medimos nosotros

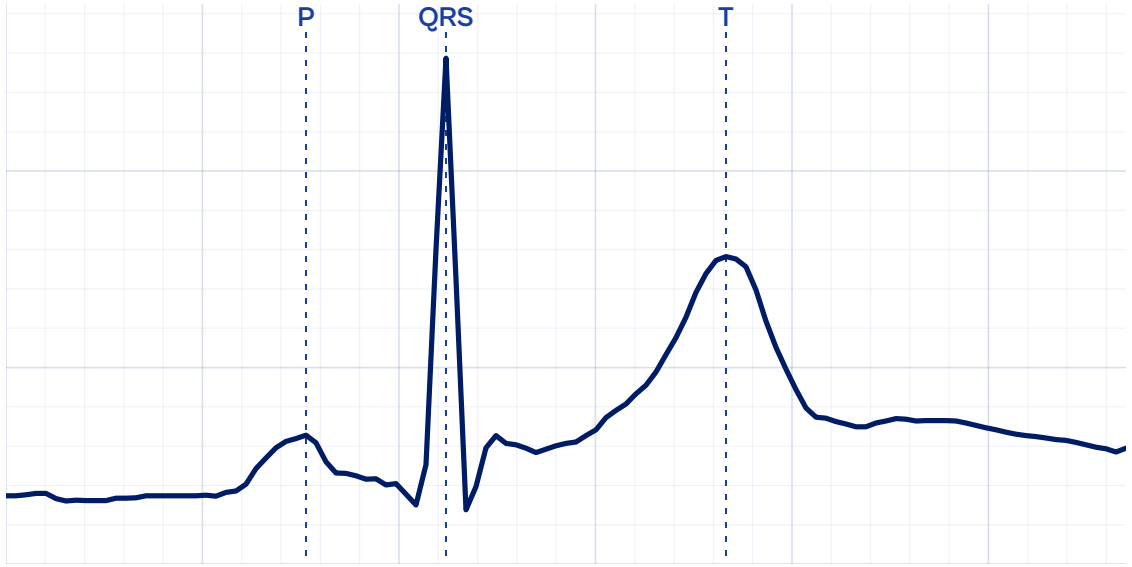
210 características por registro: amplitudes, espectro, ritmo RR, edad y sexo.

Random Forest y XGBoost.

Redes: lo que aprende el modelo

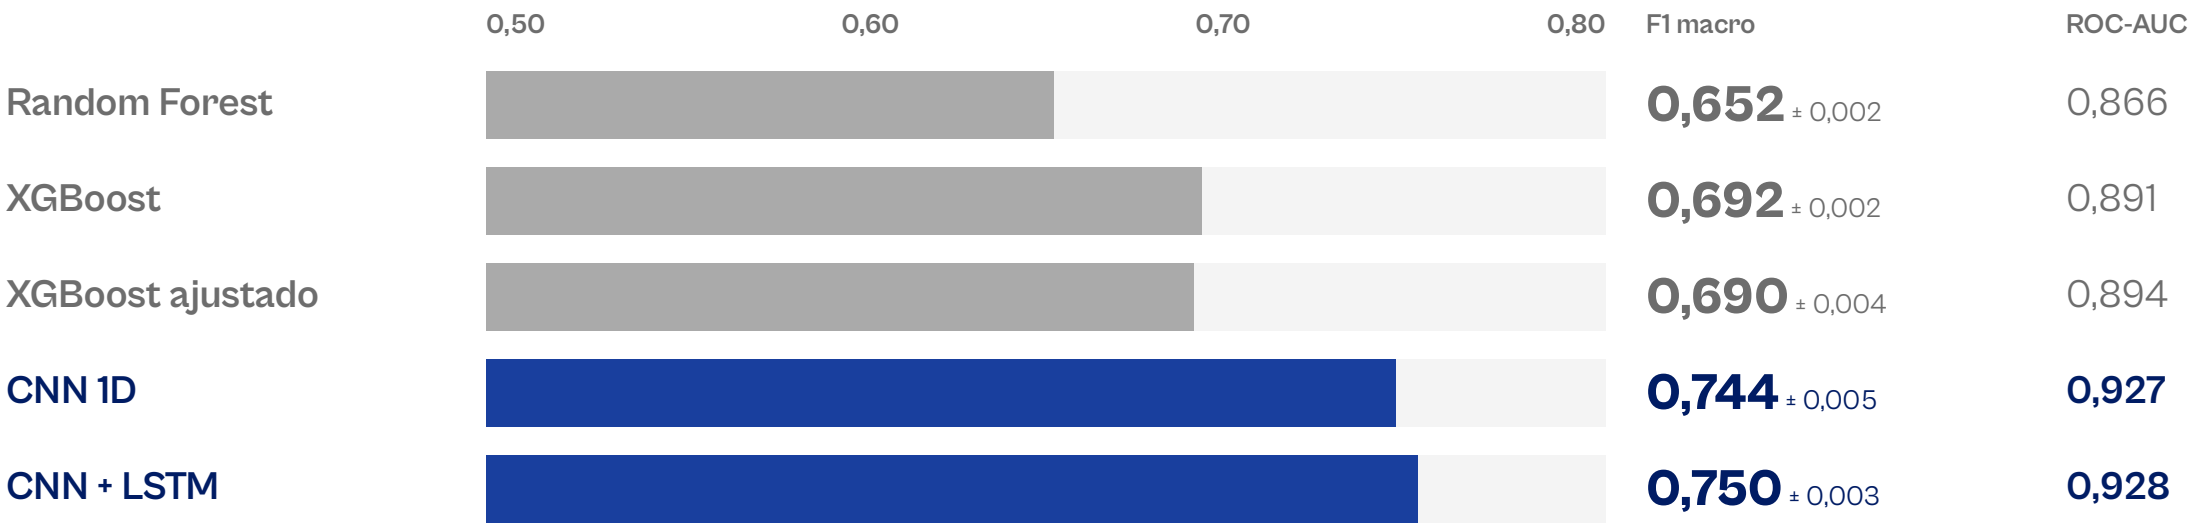
La **señal completa**, sin reglas previas.

CNN 1D residual (363.781 parámetros) y CNN + LSTM bidireccional (464.901).



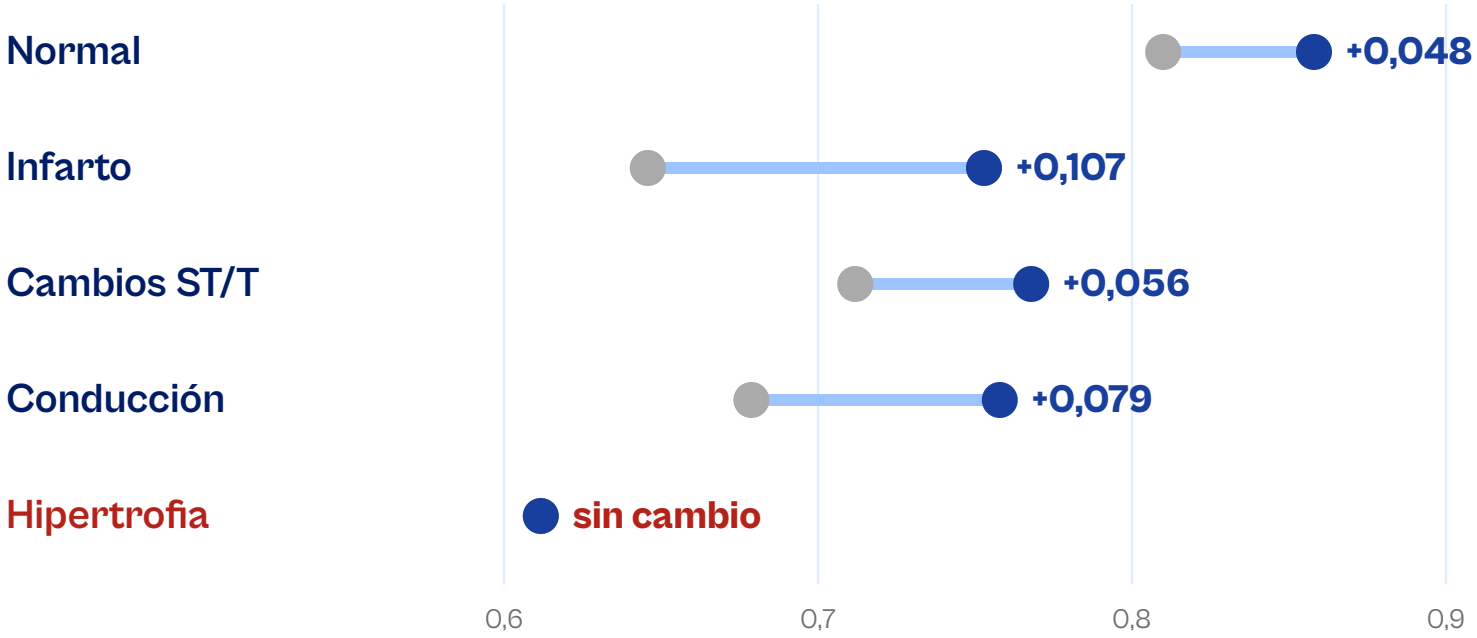
Latido real del registro 4805: onda P, complejo QRS y onda T.

Leer la señal cruda sube el F1 macro de 0,69 a 0,75



Prueba: 2.158 ECG. Media ± desviación entre tres semillas. Esa desviación mide la variación del entrenamiento, no es un intervalo de confianza. CNN 1D y CNN + LSTM quedan dentro de esa variación: no afirmamos que una supere a la otra.

La ganancia está en infarto y conducción; la hipertrofia no mejora



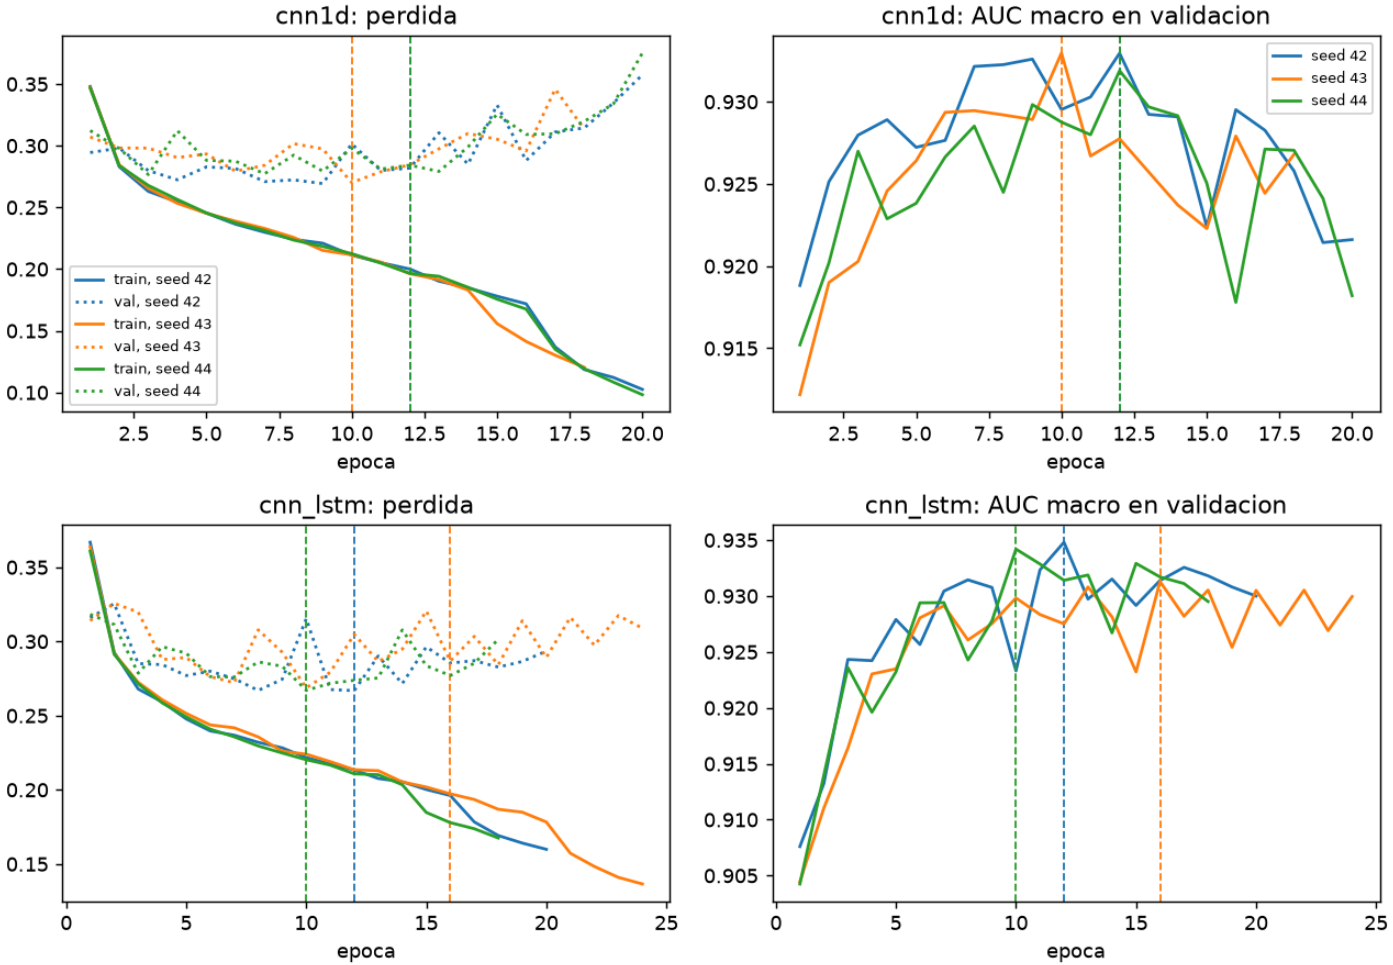
XGBoost

CNN + LSTM

F1 por clase en prueba, media de tres semillas.

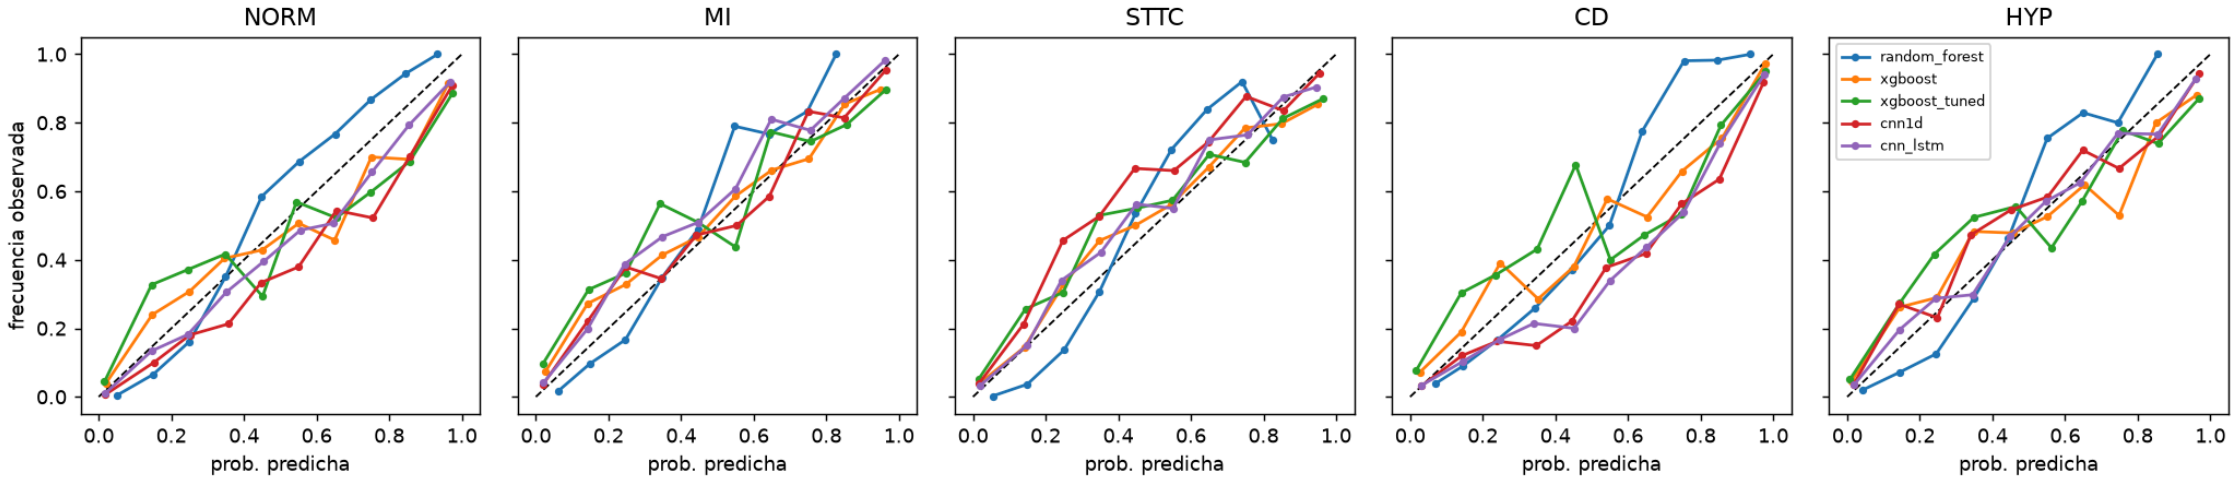
HYP es la clase menos frecuente y se queda cerca de 0,61 con todos los modelos. No probamos si el límite es el desbalance, el ruido de etiqueta o la señal.

Cada red se queda con su mejor época de validación



Máximo 60 épocas o 5 minutos por corrida, paciencia de 8 épocas y se restauran los pesos de la mejor época según AUC en validación. Dos configuraciones de CNN 1D corrieron lento y se cortaron en la época 4; lo reportamos como limitación.

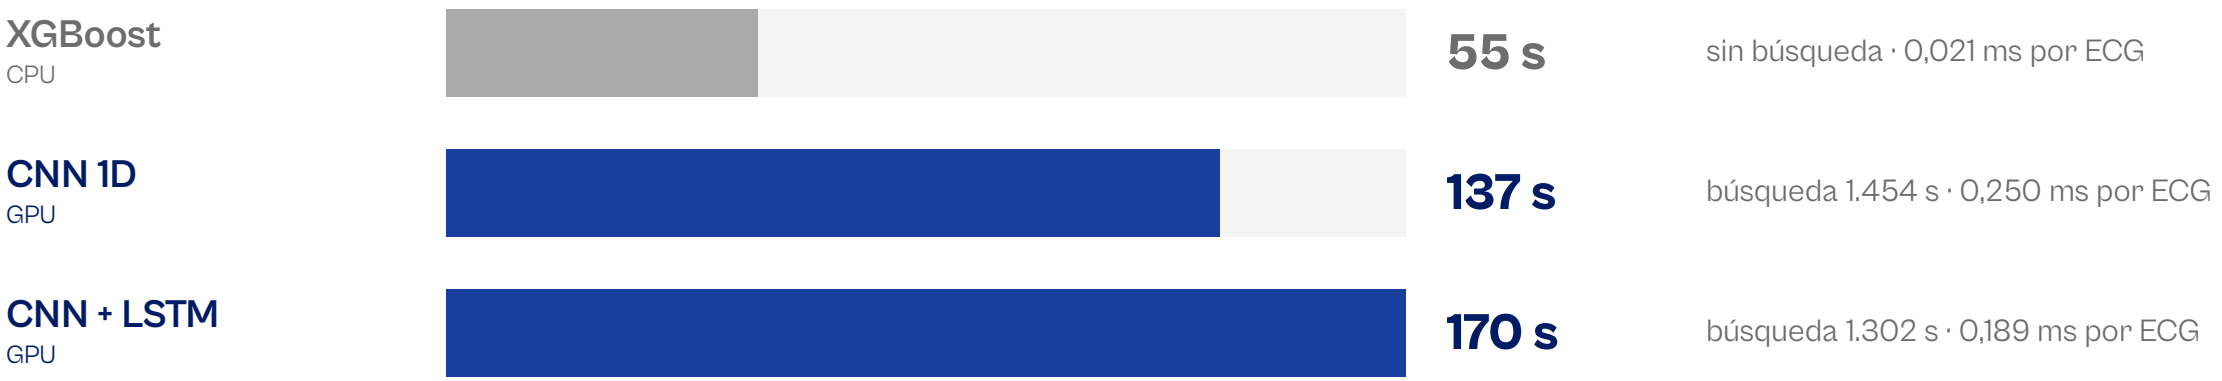
Las redes calibran mejor, pero no las recalibramos



ECE **0,049** XGBoost ECE **0,040** CNN 1D ECE **0,039** CNN + LSTM

Diagramas de la semilla 42. No aplicamos escalado de temperatura; si se hace, debe ajustarse solo en validación. Calibrar bien aquí no garantiza probabilidades confiables en otro hospital.

La mejora cuesta hasta 3 veces más tiempo de entrenamiento



Entrenamiento final medio por semilla. XGBoost corre en CPU (Ryzen 5 3600) y las redes en GPU (GTX 1660 SUPER), así que igualamos el número de configuraciones, no el cómputo total. Lo reportamos tal cual.

Lo que podemos afirmar, y lo que no

Afirmamos

- En esta partición, las redes superan a la línea base en F1, AUC y calibración.
- La mejora se concentra en infarto y trastornos de conducción.
- Ninguna decisión se tomó mirando el conjunto de prueba.

No afirmamos

- Que la CNN + LSTM sea mejor que la CNN 1D.
- Que el modelo sirva en otro hospital o con pacientes reales.
- Que funcione igual por sexo, edad o equipo: no lo medimos.

Siguiente paso: bootstrap pareado por paciente, escalado de temperatura ajustado en validación y análisis por subgrupos.

Wagner et al. (2020), Scientific Data, doi:10.1038/s41597-020-0495-6 · Strodthoff et al. (2021), IEEE JBHI, doi:10.1109/JBHI.2020.3022989 · Código: github.com/AlejoMoncada/taia-proyecto-final