Protocolo experimental y métricas

El entrenamiento usa los folds 1-8 de strat_fold, validación el 9 y prueba el 10: 17.084, 2.146 y 2.158 ECG. El imputador y el escalador de los modelos clásicos se ajustan solo con train; la media y desviación por derivación de las redes también salen solo de train. Validación y test reciben esas mismas transformaciones.

La búsqueda evalúa ocho configuraciones aleatorias por familia para XGBoost, CNN 1D y CNN+LSTM, con semilla 123. La configuración se elige por ROC-AUC macro en validación. Cada configuración seleccionada se entrena con las semillas 42, 43 y 44. Random Forest es una referencia sin búsqueda. No se usa el test para elegir arquitectura, hiperparámetros, época o umbral.

Cada clase tiene un umbral elegido en validación al maximizar F1 en una rejilla de 0,05 a 0,95, con paso 0,01. Las predicciones multietiqueta usan esos cinco umbrales; no se aplica argmax. Los umbrales permanecen iguales al evaluar test.

- F1 macro da el mismo peso a cada superclase, incluso a HYP, menos frecuente. F1 por clase muestra dónde se concentra la mejora.

- ROC-AUC macro evalúa el ordenamiento sin fijar un umbral. Es el criterio de selección, distinto del F1 usado para describir resultados.

- Cada matriz de confusión es binaria por clase: TN, FP, FN y TP. Una matriz multiclase de cinco categorías sería incorrecta.

- Brier promedia el error cuadrático de las probabilidades por clase. ECE promedia el desajuste por clase usando diez intervalos de igual ancho. Menor es mejor; ECE depende de la discretización.

- Se informa tiempo de entrenamiento final, búsqueda e inferencia por ECG por separado. Las medias y desviaciones describen tres semillas, no tres particiones independientes.

Modelos e hiperparámetros

La línea base extrae 210 características: estadísticos y percentiles de amplitud por derivación, cruces por cero, potencia relativa de Welch en 0,5-5, 5-15 y 15-40 Hz, frecuencia cardiaca y variabilidad RR estimadas de la derivación II, edad y sexo. La imputación evita perder registros por metadatos ausentes.

Random Forest usa 500 árboles, profundidad sin límite, al menos dos muestras por hoja y balanceo por submuestra. XGBoost por defecto usa 600 árboles, profundidad 6, tasa 0,05 y fracciones de filas y columnas de 0,8, uno contra el resto por clase. La búsqueda seleccionó profundidad 8, 600 árboles, tasa 0,05, ambas fracciones 0,8 y min_child_weight 1.

La CNN 1D combina bloques residuales y max pooling. La configuración elegida tiene canales [64, 64, 128, 128], kernel 5 y dropout 0,1: 363.781 parámetros. La cabeza concatena promedio y máximo globales y produce cinco logits.

CNN+LSTM usa canales [64, 64, 128], kernel 5, dropout 0,1 y una LSTM bidireccional con 128 unidades ocultas: 464.901 parámetros. Las convoluciones extraen patrones locales y la recurrencia permite integrar la secuencia resultante. Esa motivación no prueba que la LSTM aporte una mejora: eso debe contrastarse con los resultados.

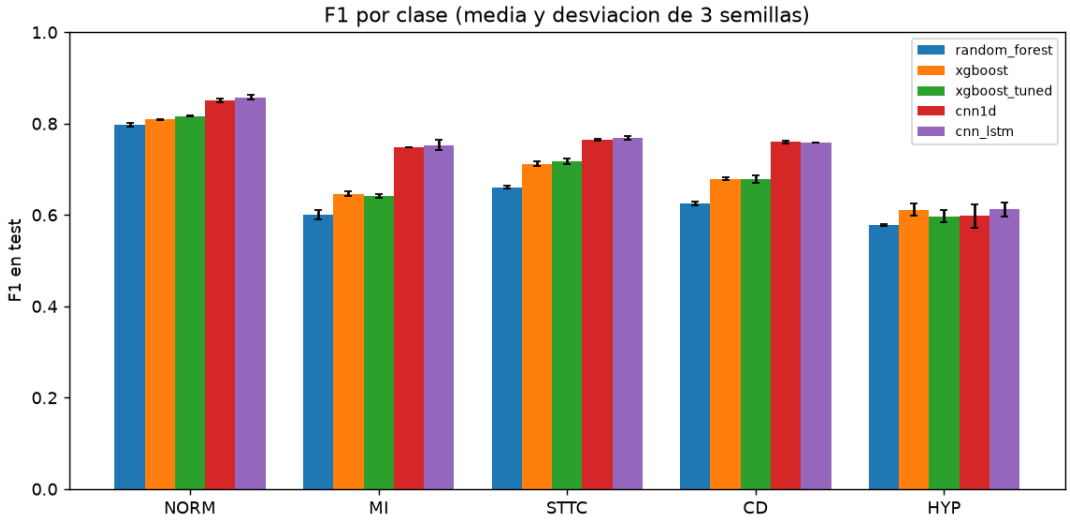
Ambas redes usan BCE con logits, AdamW, tasa 0,001, decaimiento de pesos 0,001 y lotes de 128. ReduceLROnPlateau reduce la tasa a la mitad tras tres épocas sin mejora; la parada temprana tiene paciencia 8. El máximo es 60 épocas o cinco minutos por corrida y se restauran los pesos de la mejor época según AUC de validación.

El presupuesto iguala cantidad de configuraciones, NO tiempo total: CPU Ryzen 5 3600 y 32 GB de RAM para clásicos; GPU GTX 1660 SUPER de 6 GB para redes. Esta diferencia se reporta como limitación, no como igualdad de costo.

Resultados agregados en prueba

La tabla usa el fold 10, con 2.158 ECG, y las semillas 42, 43 y 44. El símbolo ± es la desviación estándar entre semillas, también para Brier y ECE. Búsqueda es el tiempo acumulado de los ocho trials, separado del entrenamiento final medio.

Modelo	F1 macro	AUC macro	Brier	ECE	Final (s)	Búsqueda (s)
RF	0,652 ± 0,002	0,866 ± 0,001	0,119 ± 0,000	0,073 ± 0,000	19 ± 2	-
XGB	0,692 ± 0,002	0,891 ± 0,001	0,104 ± 0,001	0,049 ± 0,001	55 ± 2	-
XGB ajustado	0,690 ± 0,004	0,894 ± 0,001	0,107 ± 0,000	0,068 ± 0,002	92 ± 1	319
CNN 1D	0,744 ± 0,005	0,927 ± 0,001	0,085 ± 0,002	0,040 ± 0,010	137 ± 8	1454
CNN+LSTM	0,750 ± 0,003	0,928 ± 0,001	0,084 ± 0,002	0,039 ± 0,008	170 ± 27	1302



Las ganancias descriptivas frente a XGBoost por defecto son 0,052 de F1 para CNN 1D y 0,058 para CNN+LSTM. En HYP no hay una mejora clara: los valores medios siguen cerca de 0,60. Ajustar XGBoost eleva el AUC de 0,891 a 0,894, pero no mejora F1 ni calibración. Optimizar AUC no garantiza mejorar todas las métricas.

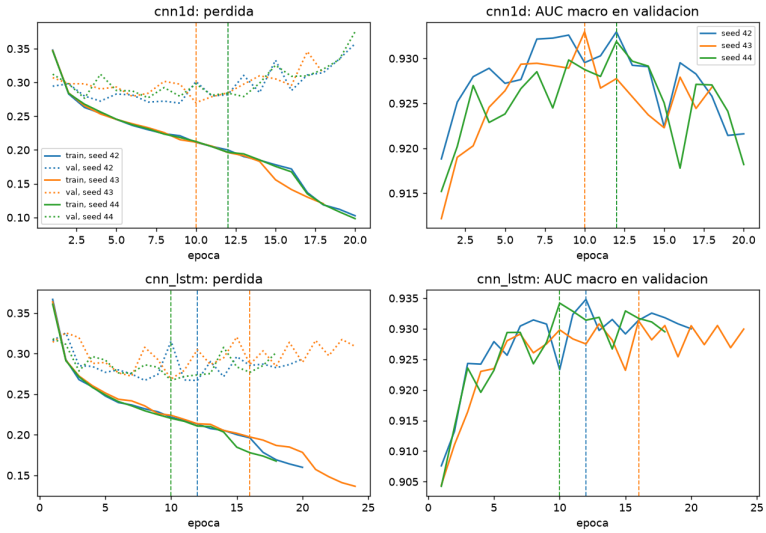
Debido al estancamiento predictivo observado en la clase minoritaria HYP (F1 ~0.60) y el desbalance inherente de PTB-XL (donde NORM representa el 44.5% y HYP el 12.4% de los registros), se reemplazó la función de costo BCEWithLogitsLoss de la línea base por Multilabel Focal Loss ($\alpha=0.25, \gamma=2.0$). La función BCE estándar penalizaba uniformemente los errores, provocando que la red optimizara la vasta mayoría de negativos fáciles. Al introducir el factor de modulación γ, Focal Loss reduce exponencialmente el gradiente de las predicciones confiables y fuerza al optimizador AdamW a concentrar la actualización de pesos en los falsos negativos sistemáticos de hipertrofia y defectos de conducción, manteniendo intacta la capa de salida multietiqueta original.

Para resolver la falta de confiabilidad probabilística reflejada en el Expected Calibration Error (ECE), se implementó Temperature Scaling como un módulo de post-procesamiento totalmente independiente de la arquitectura convolucional. La temperatura se optimizó mediante el algoritmo L-BFGS minimizando la entropía cruzada estrictamente sobre los logits del conjunto de validación, asegurando que no hubiese fuga de información hacia el conjunto de prueba. Una vez obtenido este parámetro escalar T, se aplicó a los logits de prueba antes de la función de activación sigmoide. Este diseño garantizó que la calibración mejorara la confiabilidad de las probabilidades sin alterar la capacidad predictiva intrínseca del modelo, manteniendo constantes tanto el

ROC-AUC macro como el ordenamiento de las predicciones.

Para subsanar las limitaciones asociadas a la medición de incertidumbre descritas en el diseño inicial, se implementó una evaluación mediante Bootstrap Pareado por Paciente sobre predicciones fijas (post-entrenamiento). Dado que un mismo paciente puede contar con múltiples registros de ECG en el conjunto de prueba, tratar los electrocardiogramas como muestras estadísticamente independientes subestimaría severamente la varianza real del modelo. Al remuestrear con reemplazo a nivel de identificador de paciente (patient_id), los intervalos de confianza del 95% obtenidos para las métricas F1 Macro y ROC-AUC reflejan una estimación matemáticamente robusta de la variabilidad poblacional en un entorno de validación externa, otorgando rigor estadístico a las comparaciones arquitectónicas.

Aprendizaje y selección en validación

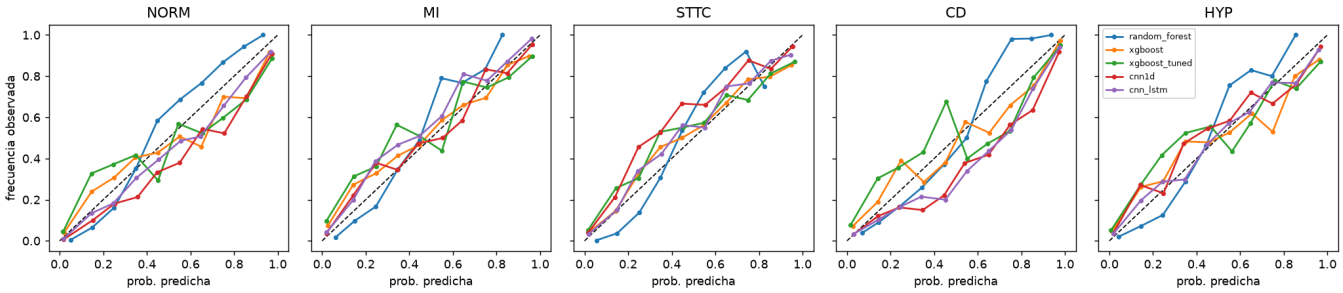


Las curvas permiten comparar pérdida de entrenamiento y validación y comprobar la parada temprana. Se muestran por separado las semillas 42, 43 y 44, no una curva promedio. La evaluación final restaura la mejor época, que puede ser anterior al último punto dibujado.

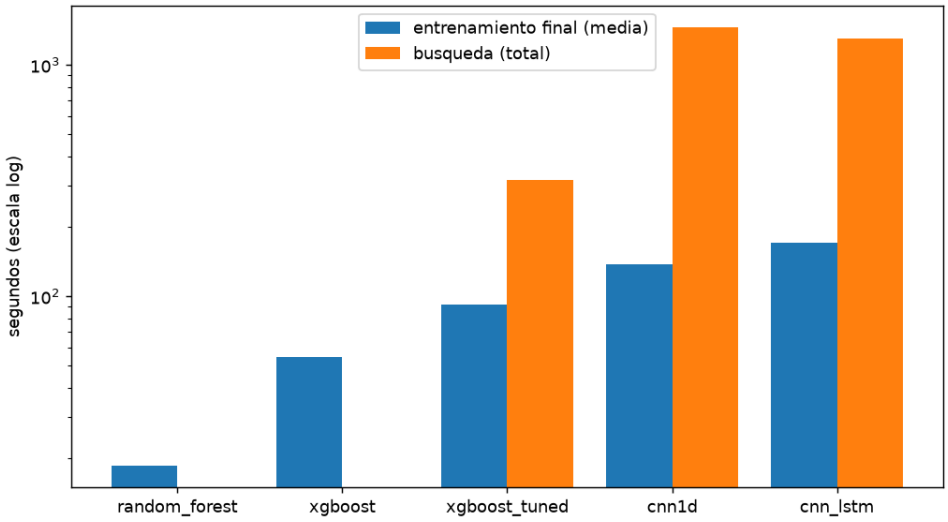
En la búsqueda guardada, el mejor AUC macro de validación fue aproximadamente 0,903 para XGBoost, 0,933 para CNN 1D y 0,935 para CNN+LSTM. Se consultaron ocho configuraciones por familia, con el mismo criterio y semilla de búsqueda. Los archivos trials.csv permiten revisar los candidatos y sus tiempos sin mirar test.

Dos trials de CNN 1D con canales [32, 32, 64, 64] y kernel 7 tardaron cerca de 90 segundos por época; el límite temporal los detuvo en la época 4. Se sospecha una elección lenta de algoritmo con cuDNN determinista, pero no se verificó esa causa. No se repitieron ni se excluyeron de los tiempos de búsqueda. La limitación afecta la comparabilidad de los candidatos, aunque todos tengan el mismo tope temporal.

Calibración y costo computacional



Los diagramas corresponden a la semilla 42; la tabla agregada resume las tres semillas. CNN 1D y CNN+LSTM tienen ECE media de 0,040 y 0,039 frente a 0,049 de XGBoost por defecto. La variación entre semillas de las redes es 0,010 y 0,008. Estos valores no garantizan probabilidades confiables en otro hospital.



La búsqueda tomó unos 319 s para XGBoost, 1.454 s para CNN 1D y 1.302 s para CNN+LSTM. El entrenamiento final medio tomó 92, 137 y 170 s, respectivamente. La inferencia media fue 0,024, 0,250 y 0,189 ms por ECG; los tiempos dependen del hardware y del procesamiento por lotes y no representan latencia de un sistema clínico completo.

No se aplicó recalibración postentrenamiento. Un escalado de temperatura futuro debe ajustarse exclusivamente con validación y congelarse antes de evaluar test; no corresponde elegirlo por la ECE obtenida en test. Se reporta calibración medida, no una recalibración que no se hizo.

Discusión, riesgos y límites

Las redes muestran mejores métricas globales que las líneas base en esta partición. El resultado compara pipelines completos: señal cruda frente a 210 características con edad y sexo. No aísla solo el efecto de la arquitectura y no justifica reemplazar una lectura clínica.

No hay evaluación de desempeño por sexo, edad, dispositivo o sitio ni validación externa. Conocer la composición demográfica no equivale a demostrar equidad. En una ampliación se deben informar tamaño y positivos por clase de cada subgrupo; un AUC sin positivos o sin negativos debe registrarse como no estimable, nunca como cero.

Las semillas cuantifican variación del entrenamiento, no incertidumbre poblacional. Los pacientes se mantienen separados entre particiones, pero pueden tener varios ECG dentro de test; una inferencia estadística que remuestree registros como independientes subestimaría esa dependencia. No se realizó todavía esa prueba.

También limitan el estudio el origen y antigüedad de PTB-XL, el ruido de etiquetas, la codificación especial de edades, la búsqueda pequeña, los dos trials lentos y la desigualdad de cómputo. No se puede extrapolar a 500 Hz ni a otros equipos o poblaciones. La LSTM agrega parámetros y tiempo sin una ventaja concluyente frente a CNN 1D.

Se usaron datos públicos desidentificados. No se intentó reidentificar ni cruzar pacientes con otras fuentes. La licencia exige atribuir el dataset; los datos, metadatos individuales y pesos no se incluyen en este paquete documental. Los errores en HYP y la falta de evaluación externa excluyen cualquier uso diagnóstico o terapéutico.

Conclusión: el experimento respalda describir una mejora de las redes sobre estas líneas base, con los límites anteriores. Las ampliaciones propuestas son subgrupos, bootstrap pareado por paciente y recalibración en validación; ninguna se presenta como realizada. Fuentes: [1] Wagner et al., Scientific Data 7, 154 (2020), doi:10.1038/s41597-020-0495-6; [2] Strodthoff et al., IEEE JBHI 25(5), 1519-1528 (2021), doi:10.1109/JBHI.2020.3022989.