Ejecución y validación: clasificación multietiqueta de ECG con PTB-XL

Grupo 9. TAIA, Maestría en Inteligencia Artificial, Universidad de La Sabana. Octubre de 2026. Integrantes: Edgar Julian Mendez Ortegon, Noel Eduardo Perez Barrios, William Alejandro Moncada Cifuentes.

Repositorio: https://github.com/AlejoMoncada/taia-proyecto-final. Semillas, particiones e hiperparámetros están en configs/default.yaml.

Protocolo experimental y métricas

El entrenamiento usa los folds 1-8 de strat_fold, validación el 9 y prueba el 10: 17.084, 2.146 y 2.158 ECG. El imputador y el escalador de los modelos clásicos se ajustan solo con train; la media y desviación por derivación de las redes también salen solo de train. Validación y test reciben esas mismas transformaciones.

La búsqueda evalúa ocho configuraciones aleatorias por familia para XGBoost, CNN 1D y CNN+LSTM, con semilla 123. La configuración se elige por ROC-AUC macro en validación. Cada configuración seleccionada se entrena con las semillas 42, 43 y 44. Random Forest es una referencia sin búsqueda. No se usa el test para elegir arquitectura, hiperparámetros, época o umbral.

Cada clase tiene un umbral elegido en validación al maximizar F1 en una rejilla de 0,05 a 0,95, con paso 0,01. Las predicciones multietiqueta usan esos cinco umbrales; no se aplica argmax. Los umbrales permanecen iguales al evaluar test.

- F1 macro da el mismo peso a cada superclase, incluso a HYP, menos frecuente. F1 por clase muestra dónde se concentra la mejora.

- ROC-AUC macro evalúa el ordenamiento sin fijar un umbral. Es el criterio de selección, distinto del F1 usado para describir resultados.

- Cada matriz de confusión es binaria por clase: TN, FP, FN y TP. Una matriz multiclase de cinco categorías sería incorrecta.

- Brier promedia el error cuadrático de las probabilidades por clase. ECE promedia el desajuste por clase usando diez intervalos de igual ancho. Menor es mejor; ECE depende de la discretización.

- Se informa tiempo de entrenamiento final, búsqueda e inferencia por ECG por separado. Las medias y desviaciones describen tres semillas, no tres particiones independientes.

Modelos e hiperparámetros

La línea base extrae 210 características: estadísticos y percentiles de amplitud por derivación, cruces por cero, potencia relativa de Welch en 0,5-5, 5-15 y 15-40 Hz, frecuencia cardiaca y variabilidad RR estimadas de la derivación II, edad y sexo. La imputación evita perder registros por metadatos ausentes.

Random Forest usa 500 árboles, profundidad sin límite, al menos dos muestras por hoja y balanceo por submuestra. XGBoost por defecto usa 600 árboles, profundidad 6, tasa 0,05 y fracciones de filas y columnas de 0,8, uno contra el resto por clase. La búsqueda seleccionó profundidad 8, 600 árboles, tasa 0,05, ambas fracciones 0,8 y min_child_weight 1.

La CNN 1D combina bloques residuales y max pooling. La configuración elegida tiene canales [64, 64, 128, 128], kernel 5 y dropout 0,1: 363.781 parámetros. La cabeza concatena promedio y máximo globales y produce cinco logits.

CNN+LSTM usa canales [64, 64, 128], kernel 5, dropout 0,1 y una LSTM bidireccional con 128 unidades ocultas: 464.901 parámetros. Las convoluciones extraen patrones locales y la recurrencia permite integrar la secuencia

resultante. Esa motivación no prueba que la LSTM aporte una mejora: eso debe contrastarse con los resultados.

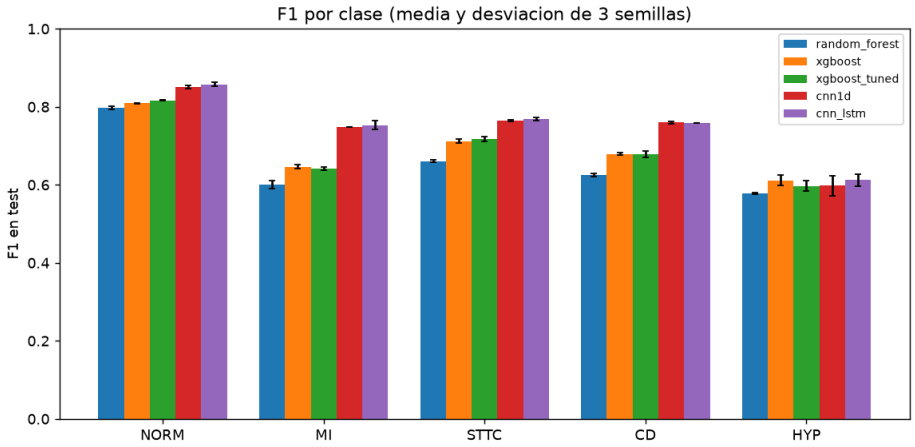
Ambas redes usan BCE con logits, AdamW, tasa 0,001, decaimiento de pesos 0,001 y lotes de 128. ReduceLROnPlateau reduce la tasa a la mitad tras tres épocas sin mejora; la parada temprana tiene paciencia 8. El máximo es 60 épocas o cinco minutos por corrida y se restauran los pesos de la mejor época según AUC de validación.

El presupuesto iguala cantidad de configuraciones, NO tiempo total: CPU Ryzen 5 3600 y 32 GB de RAM para clásicos; GPU GTX 1660 SUPER de 6 GB para redes. Esta diferencia se reporta como limitación, no como igualdad de costo.

Resultados agregados en prueba

La tabla usa el fold 10, con 2.158 ECG, y las semillas 42, 43 y 44. El símbolo ± es la desviación estándar entre semillas, también para Brier y ECE. Búsqueda es el tiempo acumulado de los ocho trials, separado del entrenamiento final medio.

Modelo	F1 macro	AUC macro	Brier	ECE	Final (s)	Búsqueda (s)
RF	0,652 ± 0,002	0,866 ± 0,001	0,119 ± 0,000	0,073 ± 0,000	19 ± 2	-
XGB	0,692 ± 0,002	0,891 ± 0,001	0,104 ± 0,001	0,049 ± 0,001	55 ± 2	-
XGB ajustado	0,690 ± 0,004	0,894 ± 0,001	0,107 ± 0,000	0,068 ± 0,002	92 ± 1	319
CNN 1D	0,744 ± 0,005	0,927 ± 0,001	0,085 ± 0,002	0,040 ± 0,010	137 ± 8	1454
CNN+LSTM	0,750 ± 0,003	0,928 ± 0,001	0,084 ± 0,002	0,039 ± 0,008	170 ± 27	1302

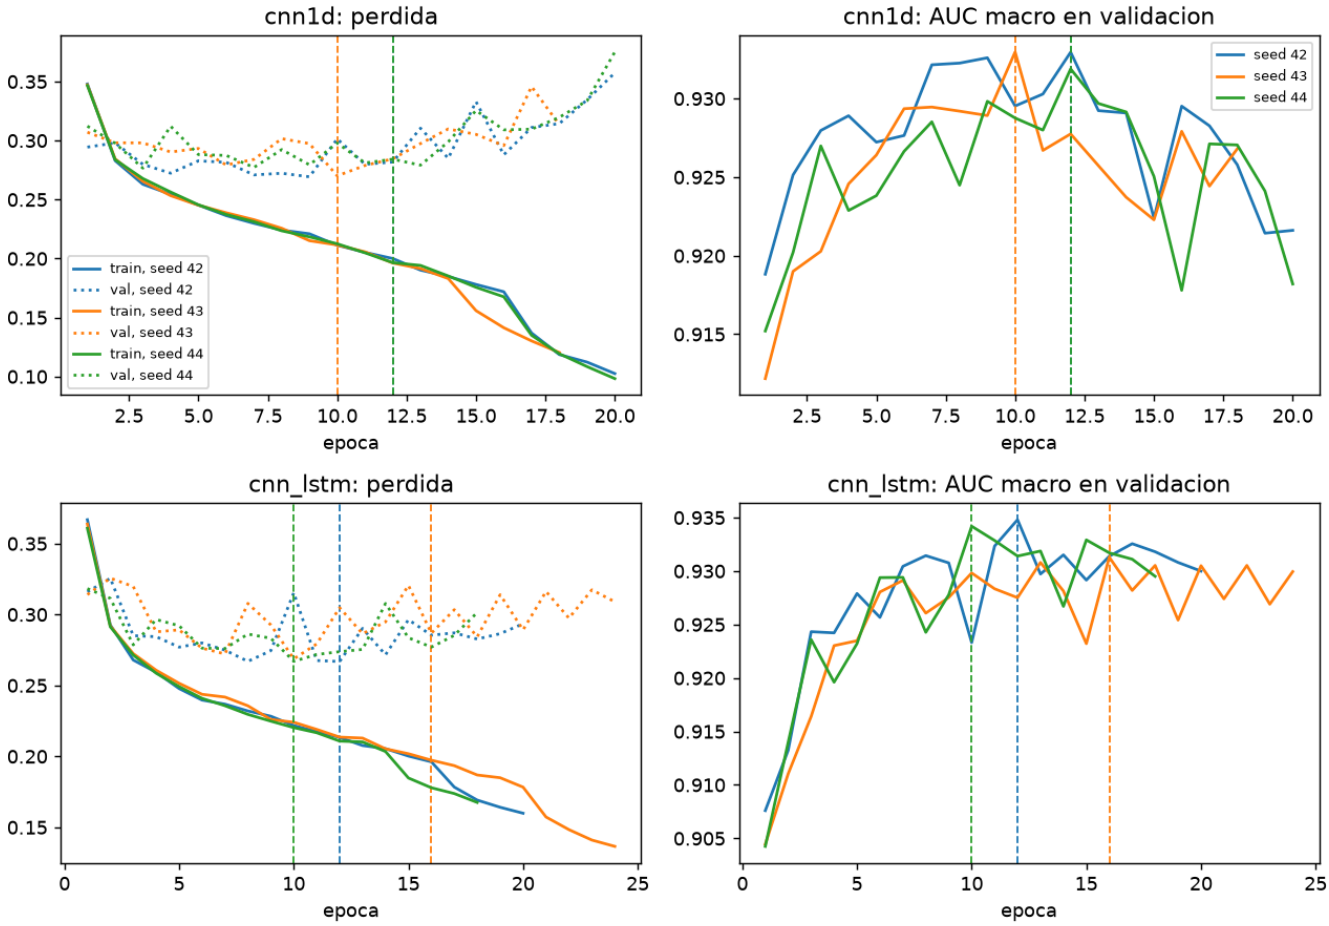


F1 por clase	NORM	MI	STTC	CD	HYP
RF	0,797 ± 0,004	0,601 ± 0,011	0,661 ± 0,003	0,625 ± 0,004	0,578 ± 0,003
XGB	0,810 ± 0,001	0,646 ± 0,005	0,712 ± 0,006	0,679 ± 0,003	0,612 ± 0,013
XGB ajustado	0,816 ± 0,001	0,642 ± 0,004	0,717 ± 0,005	0,678 ± 0,009	0,597 ± 0,013
CNN 1D	0,851 ± 0,004	0,748 ± 0,000	0,765 ± 0,002	0,760 ± 0,003	0,598 ± 0,026
CNN+LSTM	0,858 ± 0,005	0,753 ± 0,010	0,768 ± 0,004	0,758 ± 0,001	0,612 ± 0,015

Las ganancias descriptivas frente a XGBoost por defecto son 0,052 de F1 para CNN 1D y 0,058 para CNN+LSTM. En HYP no hay una mejora clara: los valores medios siguen cerca de 0,60. Ajustar XGBoost eleva el AUC de 0,891 a 0,894, pero no mejora F1 ni calibración. Optimizar AUC no garantiza mejorar todas las métricas.

El desbalance de PTB-XL, con NORM como la clase más frecuente y HYP como la menos frecuente, explica en parte el techo de HYP, que ronda F1 0,60 en todos los modelos. Las redes de esta corrida se entrenaron con BCEWithLogitsLoss, sin reponderación de clases ni pérdidas asimétricas, y no se aplicó recalibración postentrenamiento. Atacar esos dos frentes con una pérdida focal y con un escalado de temperatura ajustado en validación son las dos intervenciones que el grupo identificó como siguientes pasos; ninguna está aplicada en los resultados de arriba y por eso no se reportan cifras de ellas.

Aprendizaje y selección en validación

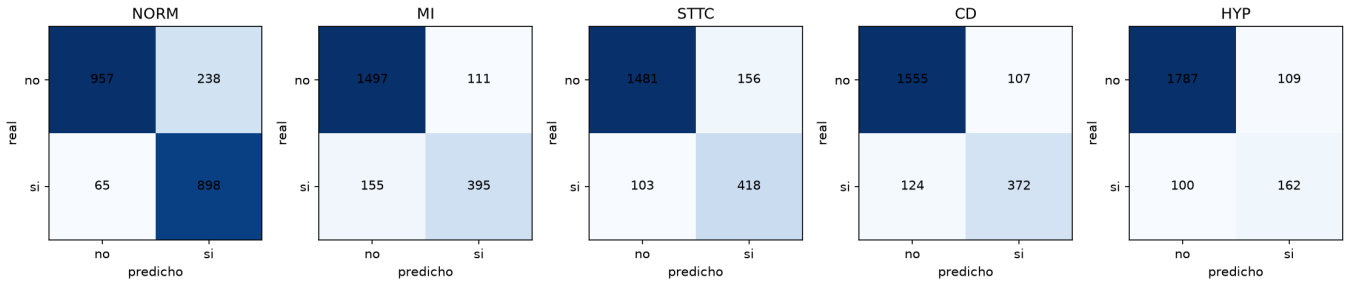


Las curvas permiten comparar pérdida de entrenamiento y validación y comprobar la parada temprana. Se muestran por separado las semillas 42, 43 y 44, no una curva promedio. La evaluación final restaura la mejor época, que puede ser anterior al último punto dibujado.

En la búsqueda guardada, el mejor AUC macro de validación fue aproximadamente 0,903 para XGBoost, 0,933 para CNN 1D y 0,935 para CNN+LSTM. Se consultaron ocho configuraciones por familia, con el mismo criterio y semilla de búsqueda. Los archivos trials.csv permiten revisar los candidatos y sus tiempos sin mirar test.

Dos trials de CNN 1D con canales [32, 32, 64, 64] y kernel 7 tardaron cerca de 90 segundos por época; el límite temporal los detuvo en la época 4. Se sospecha una elección lenta de algoritmo con cuDNN determinista, pero no se verificó esa causa. No se repitieron ni se excluyeron de los tiempos de búsqueda. La limitación afecta la comparabilidad de los candidatos, aunque todos tengan el mismo tope temporal.

Errores por clase



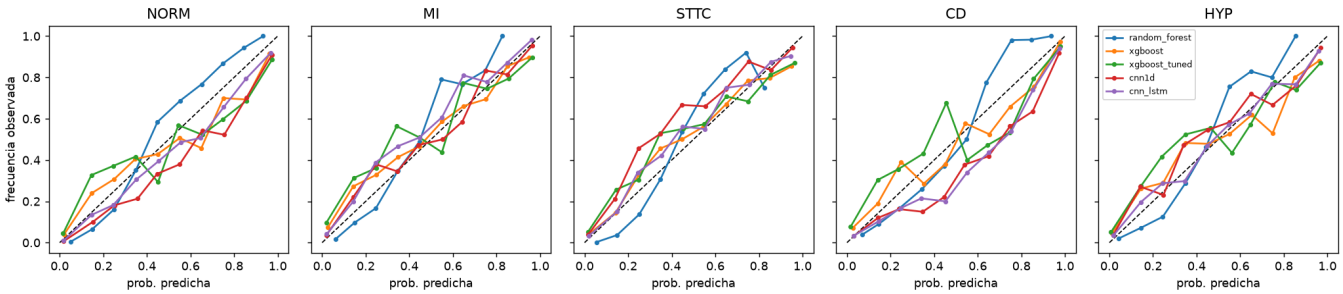
Las matrices muestran la CNN 1D, semilla 42, en test. Cada panel evalúa una etiqueta por separado y conserva tanto verdaderos negativos como positivos. No se deben sumar los soportes de las cinco clases para estimar el número de ECG: hay registros multietiqueta.

Con CNN+LSTM, el F1 medio es 0,858 en NORM, 0,753 en MI, 0,768 en STTC, 0,758 en CD y 0,612 en HYP. Para CNN 1D es 0,851, 0,748, 0,765, 0,760 y 0,598, respectivamente. CNN+LSTM no gana en todas las clases: CD queda ligeramente mejor con CNN 1D.

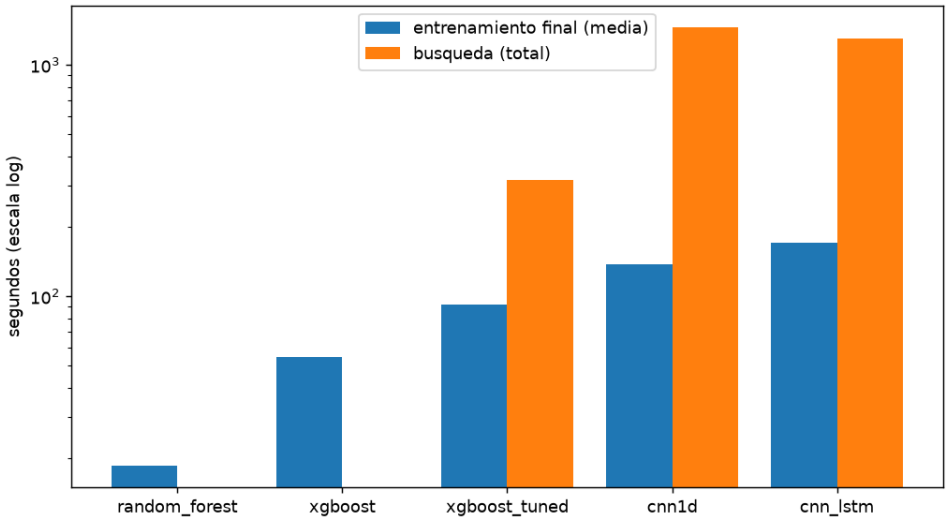
HYP tiene menor prevalencia y errores importantes. El experimento no identifica una causa única: el desbalance, el ruido de etiqueta y las limitaciones de señal o representación pueden contribuir. No se probó una intervención específica que permita atribuirles causalidad.

La diferencia de F1 macro entre redes es 0,006. Esa cercanía descriptiva no demuestra que sean equivalentes ni que una sea estadísticamente superior. Una comparación posterior debería usar un bootstrap pareado por paciente sobre predicciones fijas, manteniendo juntos los registros de cada paciente y sin cambiar hiperparámetros con el resultado.

Calibración y costo computacional



Los diagramas corresponden a la semilla 42; la tabla agregada resume las tres semillas. CNN 1D y CNN+LSTM tienen ECE media de 0,040 y 0,039 frente a 0,049 de XGBoost por defecto. La variación entre semillas de las redes es 0,010 y 0,008. Estos valores no garantizan probabilidades confiables en otro hospital.



La búsqueda tomó unos 319 s para XGBoost, 1.454 s para CNN 1D y 1.302 s para CNN+LSTM. El entrenamiento final medio tomó 92, 137 y 170 s, respectivamente. La inferencia media fue 0,024, 0,250 y 0,189 ms por ECG; los tiempos dependen del hardware y del procesamiento por lotes y no representan latencia de un sistema clínico completo.

No se aplicó recalibración postentrenamiento. Un escalado de temperatura futuro debe ajustarse exclusivamente con validación y congelarse antes de evaluar test; no corresponde elegirlo por la ECE obtenida en test. Se reporta calibración medida, no una recalibración que no se hizo.

Discusión, riesgos y límites

Las redes muestran mejores métricas globales que las líneas base en esta partición. El resultado compara pipelines completos: señal cruda frente a 210 características con edad y sexo. No aísla solo el efecto de la arquitectura y no justifica reemplazar una lectura clínica.

No hay evaluación de desempeño por sexo, edad, dispositivo o sitio ni validación externa. Conocer la composición demográfica no equivale a demostrar equidad. En una ampliación se deben informar tamaño y positivos por clase de cada subgrupo; un AUC sin positivos o sin negativos debe registrarse como no estimable, nunca como cero.

Las semillas cuantifican variación del entrenamiento, no incertidumbre poblacional. Los pacientes se mantienen separados entre particiones, pero pueden tener varios ECG dentro de test; una inferencia estadística que remuestree registros como independientes subestimaría esa dependencia. No se realizó todavía esa prueba.

También limitan el estudio el origen y antigüedad de PTB-XL, el ruido de etiquetas, la codificación especial de edades, la búsqueda pequeña, los dos trials lentos y la desigualdad de cómputo. No se puede extrapolar a 500 Hz ni a otros equipos o poblaciones. La LSTM agrega parámetros y tiempo sin una ventaja concluyente frente a CNN 1D.

Se usaron datos públicos desidentificados. No se intentó reidentificar ni cruzar pacientes con otras fuentes. La licencia exige atribuir el dataset; los datos, metadatos individuales y pesos no se incluyen en este paquete documental. Los errores en HYP y la falta de evaluación externa excluyen cualquier uso diagnóstico o terapéutico.

Conclusión: el experimento respalda describir una mejora de las redes sobre estas líneas base, con los límites anteriores. Las ampliaciones propuestas son subgrupos, bootstrap pareado por paciente y recalibración en validación; ninguna se presenta como realizada. Fuentes: [1] Wagner et al., Scientific Data 7, 154 (2020), doi:10.1038/s41597-020-0495-6; [2] Strodthoff et al., IEEE JBHI 25(5), 1519-1528 (2021), doi:10.1109/JBHI.2020.3022989.